

矩阵计算与优化

Matrix Computation and Optimization

吕月明

南京大学智能科学与技术学院



第 2 章 矩阵的标准形与特征值计算

线性代数基础回顾

- ① 对于 n 阶方阵 A ，如果存在数 λ 和非零 n 维向量 $\mathbf{X}$ ，满足

$$A\mathbf{X} = \lambda\mathbf{X}$$

那么 λ 就是 A 的特征值， $\mathbf{X}$ 就是 A 对应于 λ 的特征向量。

- ② 实矩阵的复特征值是成对出现的，比如 $\lambda = a + bi$ 是特征值，那它的共轭 $\bar{\lambda} = a - bi$ 也一定是；
- ③ 相似矩阵有相同的特征值，这个性质是我们后续做特征值隔离的关键。

特征值的估计

盖尔圆定理: 特征值的“范围定位器”

设 $A = (a_{ij})_{n \times n}$, $a_{ij} \in \mathbb{C}$, 则 A 的特征值有 $\lambda \in \bigcup_{i=1}^n D_i$, 其中

$$D_i = \left\{ z : |z - a_{ii}| \leq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| \right\} \quad (i = 1, 2, \dots, n)$$

为复平面上的圆盘.

注: 定理中的圆 D_i 也称为矩阵 A 的第 i 个盖尔圆. $R_i = \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|$

为盖尔圆 D_i 的半径.

证明

设 λ 是 A 的任意特征值, x 为 A 对应于 λ 的特征向量, 且 $|x_i| = \|x\|_\infty = 1$. 由于 $(Ax)_i = \lambda x_i$, 即 $\lambda x_i = \sum_{j=1}^n a_{ij} x_j$. 则我们有

$$(\lambda - a_{ii}) x_i = \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij} x_j$$

注意到 $|x_j| \leq |x_i| = 1 (j \neq i)$, 则由上式得

$$|\lambda - a_{ii}| \leq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| |x_j| \leq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|$$

于是 $\lambda \in D_i$.

注: A 的全体特征值也都在 A^T 的 n 个盖尔圆构成的并集中, 称 A^T 的盖尔圆为 A 的列盖尔圆.

定理

设盖尔圆定理的 n 个圆盘中, 有 m 个圆盘相交构成一个连通域 S , 且 S 与其余 $n - m$ 个圆盘严格分离, 则 S 中恰有 A 的 m 个特征值, 其中重特征值按其重数计算.

例


估计矩阵

$$A = \begin{pmatrix} -3 + i & 0 & 2 \\ -1 & 3 & i \\ 0 & -1 & 2 \end{pmatrix}$$

特征值范围.

解: 矩阵 A 的 3 个盖尔圆为


$G_1 : |z + 3 - i| \leq 2$, $G_2 : |z - 3| \leq 2$, $G_3 : |z - 2| \leq 1$, 故 A 的 3 个特征值都在 $\bigcup_{i=1}^3 G_i$ 之中.



矩阵 A 的 3 个列盖尔圆为

$$G'_1 : |z + 3 - i| \leq 1, G'_2 : |z - 3| \leq 1, G'_3 : |z - 2| \leq 3,$$

故 A 的 3 个特征值都在 $\bigcup_{i=1}^3 G'_i$ 之中.



由定理结论, 矩阵 A 的特征值在 G_1 中有一个, 在 $G_2 \cup G_3$ 中有两个;

或者一个在 G'_1 中, 两个在 $G'_2 \cup G'_3$ 中.

注: 特征值在两个或两个以上的盖尔圆构成的连通部分中的分布不一定是平均的.

如设

$$A = \begin{pmatrix} 10 & -8 \\ 5 & 0 \end{pmatrix}$$

其特征值为 $\lambda_1 = 5 - i\sqrt{15}$, $\lambda_2 = 5 + i\sqrt{15}$, 两个盖尔圆为

$$G_1 : |z - 10| \leq 8 \quad G_2 : |z| \leq 5,$$

但 A 的特征值都在 G_1 中.

如何进行特征值的隔离

* 方法 1: 行盖尔圆不行, 就用列盖尔圆.

例: 应用盖尔圆定理隔离

$$A = \begin{pmatrix} 20 & 3 & 2 \\ 2 & 10 & 4 \\ 4 & 0.5 & 0 \end{pmatrix}$$

的特征值.

解: A 的三个盖尔圆为

$$G_1 : |z - 20| \leq 5, G_2 : |z - 10| \leq 6, G_3 : |z| \leq 4.5 .$$

G_1, G_2, G_3 相交.

而 A 的三个列盖尔圆为

$G'_1 : |z - 20| \leq 6, G'_2 : |z - 10| \leq 3.5, G'_3 : |z| \leq 6$, 它们相互分离.

故在 G'_1, G'_2, G'_3 中各有 A 的一个特征值.

★ 方法 2: 相似变换法 (核心) .

- 设 $\mathbf{A} = (a_{ij})_{n \times n}$, $\mathbf{D} = \text{diag}(d_1, d_2, \dots, d_n)$,
($d_i > 0, i = 1, 2, \dots, n$) . 则

$$\mathbf{A} \sim \mathbf{B} = \mathbf{D}^{-1} \mathbf{A} \mathbf{D},$$

$\mathbf{A}$ 与 $\mathbf{B}$ 有相同的特征值.

- $\mathbf{B}$ 的圆盘半径为 $\sum_{\substack{j=1 \\ j \neq i}}^n \left| \frac{a_{ij} d_j}{d_i} \right|$.

- 适当选取 D 的元素值, 可以使某个圆盘半径相对减小. 一般地,
 - * 要使 A 的第 i 个盖尔圆半径放大, 其余盖尔圆适量缩小 (相对于 A 的同序号盖尔圆), 我们可取 $d_i < 1$, 其它元素值取 1;
 - * 相反, 若使 A 的第 i 个盖尔圆半径缩小, 其余盖尔圆适量放大 (相对于 A 的同序号盖尔圆), 我们可取 $d_i > 1$, 其它元素值取 1;

例

应用盖尔圆定理隔离

$$A = \begin{pmatrix} 2 & 2 & -1 \\ 1 & 10 & -1 \\ 8 & 2 & 20 \end{pmatrix}$$

的特征值.

解: A 的三个盖尔圆为

$$G_1 : |z - 2| \leq 3, G_2 : |z - 10| \leq 2, G_3 : |z - 20| \leq 10.$$

 G_2 与 G_3 相交.

取 $D = \text{diag}(\frac{1}{2}, 1, 1)$, 则

$$B = D^{-1}AD = \begin{pmatrix} 2 & 4 & -2 \\ 0.5 & 10 & -1 \\ 4 & 2 & 20 \end{pmatrix}$$

从而 B 的三个盖尔圆为

$$G'_1 : |z - 2| \leq 6, G'_2 : |z - 10| \leq 1.5, G'_3 : |z - 20| \leq 6,$$

它们相互分离. 所以 A 的三个特征值分别在 G'_1, G'_2, G'_3 中. 若实矩阵 A 的特征值 λ 为复数, 则 $\bar{\lambda}$ 也为特征值, 但 G'_1, G'_2, G'_3 关于实轴对称, 则 A 特征值必皆为实数, 故在区间 $[-1, 5], [8.5, 11.5], [14, 26]$ 中各有 A 的一个特征值.

幂迭代法与逆幂迭代法

幂迭代法

- 设矩阵 A 可对角化, 其特征值满足

$$|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$$

且 $x_1, x_2, \cdots, x_n$ 为相应线性无关的特征向量.

- 矩阵 A 按模最大的特征值 λ_1 称为主特征值, 对应 x_1 称为主特征向量.

算法思想

设 v 是 $\mathbf{R}^n$ 的任意元素, 则有

$$v = \alpha_1 x_1 + \alpha_2 x_2 + \cdots + \alpha_n x_n.$$

得

$$A^k v = \lambda_1^k \left[\alpha_1 x_1 + \sum_{i=2}^n \alpha_i \left(\frac{\lambda_i}{\lambda_1} \right)^k x_i \right].$$

- 当 $k \rightarrow \infty$, $\left(\frac{\lambda_i}{\lambda_1}\right)^k \rightarrow 0$. 且当 $\alpha_1 \neq 0$ 时, $A^k v$ 除去一个数量因子外, 趋向于向量 x_1 .
- 当 $|\lambda_1| > 1$ 时, $|\lambda_1|^k$ 趋向于无穷; 而 $|\lambda_1| < 1$ 时, $|\lambda_1|^k$ 趋向于 0.

迭代中加入规范化步骤. 令

$\mathbf{x} = (\xi_1, \xi_2, \dots, \xi_n)^T \in \mathbf{R}^n$, 记

$$\max(\mathbf{x}) = \xi_i, \quad |\xi_i| = \|\mathbf{x}\|_\infty.$$

迭代格式

选取向量 $v_0 \neq 0$ ，做迭代

$$\begin{cases} u_0 = v_0 \neq 0 \\ v_k = Au_{k-1} \\ m_k = \max(v_k) \quad k = 1, 2, \dots \\ u_k = \frac{v_k}{m_k} \end{cases}$$

收敛分析

- $\mathbf{u}_k \rightarrow \frac{\mathbf{x}_1}{\max(\mathbf{x}_1)}$.
- $\mathbf{m}_k = \lambda_1 \left[1 + O\left(\left|\frac{\lambda_2}{\lambda_1}\right|^k\right) \right] \rightarrow \lambda_1$.
- 收敛速度取决于 $\left|\frac{\lambda_2}{\lambda_1}\right|$

例

计算矩阵

$$A = \begin{pmatrix} 2 & 3 & 2 \\ 10 & 3 & 4 \\ 3 & 6 & 1 \end{pmatrix}$$

的按模最大的特征值及特征向量. 当 $\|\mathbf{u}_k - \mathbf{u}_{k+1}\|_\infty \leq 10^{-4}$ 时停止计算.

取 $v_0 = (0, 0, 1)^T$ ，计算结果见表

k	v_k^T	u_k^T	m_k
0	(0, 0, 1)	(0, 0, 1)	
1	(2, 4, 1)	(0.5, 1.0, 0.25)	4
2	(4.5, 9.0, 7.7500)	(0.5, 1.0, 0.8611)	9
3	(5.7222, 11.4444, 8.3511)	(0.5, 1.0, 0.7306)	11.4444
4	(5.4612, 10.9224, 8.2306)	(0.5, 1.0, 0.7535)	10.9224
5	(5.5070, 11.0410, 8.2535)	(0.5, 1.0, 0.7493)	11.0140
6	(5.4986, 10.9972, 8.2493)	(0.5, 1.0, 0.7501)	10.9972
7	(5.5003, 11.0004, 8.2501)	(0.5, 1.0, 0.7500)	11.0004
8	(5.5000, 11.0000, 8.2500)	(0.5, 1.0, 0.7500)	11.0000

所以按模最大特征值为 $\lambda_1 = 11$ ，特征向量为 $x_1 = (0.5, 1, 0.75)^T$

逆幂迭代法

★ 应用 1: 计算非奇异矩阵 A 按模最小特征值及相应特征向量.

- A 非奇异, 且

$0 < |\lambda_n| < |\lambda_{n-1}| \leq \cdots |\lambda_2| \leq |\lambda_1|$, 则 A 的按模最小特征值 λ_n 的倒数恰好为 A^{-1} 的按模最大特征值.

- 对 A^{-1} 应用幂迭代法.

算法结构

迭代格式

$$\begin{cases} u_0 = v_0 \neq 0, \\ Av_k = u_{k-1}, \\ m_k = \max(v_k), \quad k = 1, 2, \dots \\ u_k = \frac{v_k}{m_k} \end{cases}$$

- $\mathbf{m}_k \rightarrow \frac{1}{\lambda_n}, \mathbf{u}_k \rightarrow \frac{\mathbf{x}_n}{\max(\mathbf{x}_n)}$.
- 将 A 进行 LU 分解, 每次迭代求解两个三角形方程组.

* 应用 2: 已知矩阵 A 的特征值 λ_i 的近似值 p , 对 $A - pI$ 实行逆幂迭代法计算 λ_i .

$$\begin{cases} (A - pI) v_k = u_{k-1} \\ m_k = \max(v_k) \quad (k = 1, 2, \dots) \\ u_k = \frac{v_k}{m_k} \end{cases}$$

收敛性

当 $k \rightarrow \infty$ 时, 有

$$\mathbf{u}_k \rightarrow \frac{\mathbf{x}_i}{\max(\mathbf{x}_i)}$$

$$\mathbf{m}_k \rightarrow \frac{1}{\lambda_i - p} = \hat{\lambda}$$

所以 $\lambda_i = \frac{1}{\hat{\lambda}} + p$.

- $A - pI$ 接近奇异, 有必要采用选列主元作三角分解

$$P(A - pI) = LU.$$

算法改进:

$$\begin{cases} Ly_k = Pu_{k-1} \\ Uv_k = y_k \\ m_k = \max(v_k) \quad (k = 1, 2, \dots) \\ u_k = \frac{v_k}{m_k} \end{cases}$$

例

用逆幂法求矩阵 $\mathbf{A} = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 3 & 0 \\ 1 & 1 & 4 \end{pmatrix}$ 最接近 3.5 的特征值和相应

特征向量. 初始向量设为 $(1, 1, 1)^T$, 停机准则设为

$\|v_{k+1} - v_k\| \leq 10^{-4}$. (精确值 $\frac{5+\sqrt{5}}{2}$).

解: 因为

$$A - 3.5I_3 = \begin{pmatrix} -1.5 & 1 & 0 \\ 1 & -0.5 & 0 \\ 1 & 1 & 0.5 \end{pmatrix}$$

列主元三角分解 $P(A - 3.5I_3) = LU$, 其中

$$P = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

$$L = \begin{pmatrix} 1 & 0 & 0 \\ -0.6667 & 1 & 0 \\ -0.6667 & 0.1 & 1 \end{pmatrix}, U = \begin{pmatrix} -1.5 & 1 & 0 \\ 0 & 1.6667 & 0.5 \\ 0 & 0 & -0.05 \end{pmatrix}.$$

计算结果见表

k	u_k^T			m_k
1	-0.2	-0.3333	1.0000	-30.0006
2	-0.1566	-0.2530	1.0000	11.0667
3	-0.1482	-0.2399	1.0000	8.9398
4	-0.1464	-0.2370	1.0000	8.5768
5	-0.1460	-0.2363	1.0000	8.4965
6	-0.1459	-0.2361	1.0000	8.4779
7	-0.1459	-0.2361	1.0000	8.4735

则

$$\lambda \approx 3.5 + \frac{1}{8.4735} = 3.6180,$$

近似特征向量为

$$x \approx u_7 = (-0.1459, -0.2361, 1.0000)^T.$$

Takeaways:

1. 盖尔圆定理：特征值的范围估计，连通域推论是隔离的基础；
2. 特征值隔离方法：行转列、相似变换法；
3. 特征值数值计算方法：幂迭代法，逆幂迭代法。

END
of
Chapter 2