



矩阵计算与优化

(非线性规划之有约束优化)

智能科学与技术学院
吕月明



南京大學
NANJING UNIVERSITY



大纲

- 约束极值及最优性条件
- 约束极值问题的算法



约束极值问题的一般表示 $\min f(x)$

$$s.t. \quad \begin{cases} h_i(x) = 0 & i = 1, 2, \dots, m \\ g_j(x) \leq 0 & j = 1, 2, \dots, l \end{cases}$$

记 $h(x) = (h_1(x), h_2(x), \dots, h_m(x))^T$,

$g(x) = (g_1(x), g_2(x), \dots, g_l(x))^T$,

为简便, 写成矩阵形式 $\min f(x)$

$$s.t. \quad \begin{cases} h(x) = 0 \\ g(x) \leq 0 \end{cases}$$

令 $Q = \{x | h(x) = 0, g(x) \leq 0\}$, 称 Q 为此约束极值问题的可行域。



约束极值的最优性条件—Kuhn-Tucker 条件

1. 等式约束问题的最优性条件

考虑

$$\min f(x)$$

$$\text{s.t. } h(x)=0$$



回顾高等数学中所学的**条件极值**：在 $\phi(x,y)=0$ 的条件下，求 $z = f(x,y)$ 极值

$$\text{即：} \quad \min f(x,y) \quad \text{s.t.} \quad \phi(x,y)=0$$

引入Lagrange乘子： λ

$$\text{Lagrange函数} \quad L(x,y;\lambda) = f(x,y) + \lambda \phi(x,y)$$

若 (x^*, y^*) 是条件极值，则存在 λ^* ，使得

$$\begin{cases} f_x(x^*, y^*) + \lambda^* \phi_x(x^*, y^*) = 0 \\ f_y(x^*, y^*) + \lambda^* \phi_y(x^*, y^*) = 0 \\ \phi(x^*, y^*) = 0 \end{cases}$$



推广到多元情况, 可得到对于等式约束的最优性条件:


$$\text{分量形式: } \begin{cases} \min f(x) \\ \text{s.t. } h_j(x) = 0, \quad j = 1, 2, \dots, l \end{cases}$$

若 x^* 是其的最优解, 则存在 $v^* \in R^l$ 使

$$\nabla f(x^*) + \sum_{j=1}^l v_j^* \nabla h_j(x^*) = 0$$



几何意义： 考虑一个约束的情况：



这里 x^* 最优, $\nabla f(x^*)$ 与
 $\nabla h(x^*)$ 共线, 而 x' 非最优
 $\nabla f(x')$ 与 $\nabla h(x')$ 不共线,

最优性条件即:
$$\nabla f(x^*) + \sum_{j=1}^l \nu_j^* \nabla h_j(x^*) = 0$$



约束极值的最优性条件——Kuhn-Tucker 条件

2. 不等式约束问题的最优性条件

$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & g(x) \leq 0\end{array}$$


可行域为 $Q = \{x | g(x) \leq 0\}$ 。



①可行方向与积极约束:

可行方向:

设 $x^0 \in Q$, d 为一个向量。如果存在 实数 $\bar{\lambda} > 0$, 使得对任意的 $\lambda \in [0, \bar{\lambda}]$ 有 $x^0 + \lambda d \in Q$, 则称 d 为 x^0 处的一个可行方向。





①可行方向与积极约束:

积极约束:

设点 $\bar{x} \in Q$, 对于不等式约束 $g_i(x) \leq 0$, 如果 $g_i(\bar{x}) = 0$, 则称 $g_i(x) \leq 0$ 是点 $\bar{x}$ 处的积极约束。

或 **起作用约束**（**紧约束\积极约束\有效约束**）。


记 $I(\bar{x}) = \{i | g_i(\bar{x}) = 0, 1 \leq i \leq l\}$, 称 $I(\bar{x})$ 为点 $\bar{x}$ 处的积极约束指标集。



矩阵计算与优化 (非线性规划-有约束优化)

例: 设 $g_1(x) = \sqrt{2}x_1^2 - x_2 \leq 0$, $g_2(x) = x_1^2 + x_2^2 - 1 \leq 0$,
 $g_3(x) = -x_1 \leq 0$ 。令 $\bar{x} = (\frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2})^T$, 求点 $\bar{x}$ 的积极约束指标集。

解: $\because g_1(\bar{x}) = \sqrt{2} \times (\frac{\sqrt{2}}{2})^2 - \frac{\sqrt{2}}{2} = 0$,
 $g_2(\bar{x}) = (\frac{\sqrt{2}}{2})^2 + (\frac{\sqrt{2}}{2})^2 - 1 = 0$,
 $g_3(\bar{x}) = -\frac{\sqrt{2}}{2} < 0$.
 $\therefore I(\bar{x}) = \{1, 2\}$ 。





②如何判断一个方向是可行方向和可行下降方向?

定理1: 给定点 $\bar{x} \in Q$, 记点 $\bar{x}$ 的积极约束指标集为 $I(\bar{x})$ 。给定向量 d , 如果对任意的 $i \in I(\bar{x})$ 有 $\nabla g_i(\bar{x})^T d < 0$, 则 d 是点 $\bar{x}$ 的可行方向。

证明: 令 $x' = \bar{x} + td, t > 0$ 。则对任意的 $i \in I(\bar{x})$, 有

$$\begin{aligned} g_i(x') &= g_i(\bar{x}) + t \nabla g_i(\bar{x})^T d + o(\|td\|^2) \\ &= t \nabla g_i(\bar{x})^T d + o(\|td\|^2) < 0 \end{aligned}$$

$\therefore x' \in Q$, 即 d 为可行方向。



可行下降方向:

设点 $\bar{x} \in Q$, 给定向量 d , 如果 d 既是点 $\bar{x}$ 处的可行方向, 又是该点的下降方向, 则称 d 为点 $\bar{x}$ 处的可行下降方向。

定理2: 给定点 $\bar{x} \in Q$, 记点 $\bar{x}$ 的积极约束指标集为 $I(\bar{x})$ 。给定向量 d , 如果 d 满足

$$\begin{cases} \nabla g_i(\bar{x})^T d < 0 & i \in I(\bar{x}) \\ \nabla f(\bar{x})^T d < 0 \end{cases}$$

则向量 d 是点 $\bar{x}$ 处的可行下降方向。

证略



③极值点的必要条件:

定理3: 设 $x^* \in Q$, $I(x^*)$ 是其积极约束指标集。

$f(x)$ 和 $g_i(x) (i \in I(x^*))$ 在点 x^* 处可微,

$g_i(x) (i \notin I(x^*))$ 在点 x^* 处连续。

如果 x^* 是约束极值问题的局部极小点, 则在点 x^* 处没有可行下降方向。

则由定理 2 可知, 不存在向量 d , 使下式成立

$$\begin{cases} \nabla g_i(x^*)^T d < 0 & i \in I(x^*) \\ \nabla f(x^*)^T d < 0 \end{cases}。$$



分析: (1) 如果 $I(x^*)$ 中只有一个指标, 不妨 设 $g_1(x)$ 为积极约束。


则不存在向量 d 使得

$$\begin{cases} \nabla g_1(x^*)^T d < 0 \\ \nabla f(x^*)^T d < 0 \end{cases}$$

成立。

则有 $\nabla f(x^*) = -\lambda \nabla g_1(x^*), \lambda > 0$ 。


即 $\nabla f(x^*) + \lambda \nabla g_1(x^*) = 0$ 。





矩阵计算与优化 (非线性规划-有约束优化)

分析: (2) 如果 $I(x^*)$ 中有两个指标, 不妨设 $g_1(x)$ 和 $g_2(x)$ 为积极约束。
并设 $\nabla g_1(x^*)$ 和 $\nabla g_2(x^*)$ 线性无关。



则 存在 $\lambda_1, \lambda_2 > 0$, 使得 $\nabla f(x^*) = -\lambda_1 \nabla g_1(x^*) - \lambda_2 \nabla g_2(x^*)$ 。
 $\therefore \nabla f(x^*) + \lambda_1 \nabla g_1(x^*) + \lambda_2 \nabla g_2(x^*) = 0$ 。



推广到一般情况，不等式约束问题的最优性条件：

定理4 (K-T条件): 设 $x^* \in Q$, $f(x)$ 和 $g_i(x) (i \in I(x^*))$ 在 x^* 处可微, $g_i(x) (i \notin I(x^*))$ 在点 x^* 处连续, $\{\nabla g_i(x^*) | i \in I(x^*)\}$ 线性无关。若 x^* 是约束极值问题 (1) 的局部极小点, 则存在一组实数 λ_i 使其满足

$$\begin{cases} \nabla f(x^*) + \sum_{i=1}^l \lambda_i \nabla g_i(x^*) = 0 \\ \lambda_i g_i(x^*) = 0, \lambda_i \geq 0, \quad i = 1, 2, \dots, l \end{cases}$$

上式称为K-T条件（库恩-塔克条件），满足上式的点称为K-T点。



3. 一般约束问题的最优性条件

对于一般的约束极值问题

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & \begin{cases} h(x) = 0 \\ g(x) \leq 0 \end{cases} \end{array}$$

K - T条件可统一表述为什么形式?



一般问题的最优性条件:

定理5 (K-T条件): 设 $x^* \in Q$, $f(x)$ 和 $g_i(x) (i \in I(x^*))$ 在 x^* 处可微, $g_i(x) (i \notin I(x^*))$ 在点 x^* 处连续, $\{\nabla g_i(x^*) | i \in I(x^*)\}$ 线性无关。若 x^* 是约束极值问题 (cnlp) 的局部极小点, 则存在一组实数 λ_i 使其满足

$$\begin{cases} \nabla f(x^*) + \sum_{j=1}^m u_j \nabla h_j(x^*) + \sum_{i=1}^l \lambda_i \nabla g_i(x^*) = 0 \\ \lambda_i g_i(x^*) = 0, \lambda_i \geq 0, \quad i = 1, 2, \dots, l \end{cases}$$

上式称为K-T条件 (库恩-塔克条件), 满足上式的点称为K-T点。



矩阵计算与优化 (非线性规划-有约束优化)

例：求约束极值问题的K-T点

$$\begin{aligned} \min \quad & f(x) = x_1^2 + x_2^2 - 6x_1 - 6x_2 + 8 \\ \text{s.t.} \quad & \begin{cases} x_1 + x_2 \leq 4 \\ x_1 \geq 0 \\ x_2 \geq 0 \end{cases} \end{aligned}$$

解： $\nabla f(x) = 2[x_1 - 3, x_2 - 3]^T$ 。

$$g_1(x) = x_1 + x_2 - 4, \quad \nabla g_1(x) = [1, 1]^T$$

$$g_2(x) = -x_1, \quad \nabla g_2(x) = [-1, 0]^T$$

$$g_3(x) = -x_2, \quad \nabla g_3(x) = [0, -1]^T$$



矩阵计算与优化 (非线性规划-有约束优化)

由K-T条件得

$$\begin{bmatrix} x_1 - 3 \\ x_2 - 3 \end{bmatrix} + \lambda_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \lambda_2 \begin{bmatrix} -1 \\ 0 \end{bmatrix} + \lambda_3 \begin{bmatrix} 0 \\ -1 \end{bmatrix} = 0$$

由K-T条件及约束条件得

$$\begin{cases} x_1 + \lambda_1 - \lambda_2 = 3 \\ x_2 + \lambda_1 - \lambda_3 = 3 \\ \lambda_1(x_1 + x_2 - 4) = 0 \\ -\lambda_2 x_1 = 0 \\ -\lambda_3 x_2 = 0 \\ x_1 + x_2 - 4 \leq 0 \\ \lambda_1, \lambda_2, \lambda_3, x_1, x_2 \geq 0 \end{cases}$$

以下分情况讨论:



(1) 若 $x_1 = x_2 = 0$:

由 $\lambda_1(x_1 + x_2 - 4) = 0$ 可得 $\lambda_1 = 0$ 。

$$\therefore \lambda_1 - \lambda_2 = 3 \Rightarrow \lambda_2 = -3$$

这与 $\lambda_2 \geq 0$ 矛盾。

(2) 若 $x_1 = 0, x_2 \neq 0$:

$$\therefore \lambda_3 = 0$$

$$\therefore \begin{cases} x_2 + \lambda_1 = 3 \\ \lambda_1 - \lambda_2 = 3 \end{cases} \Rightarrow x_2 + \lambda_2 = 0 \Rightarrow \lambda_2 = -x_2 < 0$$

这与 $\lambda_2 \geq 0$ 矛盾。

(3) 若 $x_1 \neq 0, x_2 = 0$:

$$\therefore \lambda_2 = 0$$

$$\begin{cases} x_1 + \lambda_1 - \lambda_2 = 3 \\ x_2 + \lambda_1 - \lambda_3 = 3 \\ \lambda_1(x_1 + x_2 - 4) = 0 \\ -\lambda_2 x_1 = 0 \\ -\lambda_3 x_2 = 0 \\ x_1 + x_2 - 4 \leq 0 \\ \lambda_1, \lambda_2, \lambda_3, x_1, x_2 \geq 0 \end{cases}$$



矩阵计算与优化 (非线性规划-有约束优化)

$$\therefore \begin{cases} x_1 + \lambda_1 = 3 \\ \lambda_1 - \lambda_3 = 3 \end{cases} \Rightarrow x_1 + \lambda_3 = 0 \Rightarrow \lambda_3 = -x_1 < 0$$

这与 $\lambda_3 \geq 0$ 矛盾。

(4) 若 $x_1 \neq 0, x_2 \neq 0$:

$$\therefore \lambda_2 = \lambda_3 = 0$$

$$\therefore \begin{cases} x_1 + \lambda_1 = 3 \\ x_2 + \lambda_1 = 3 \end{cases} \Rightarrow x_1 = x_2$$

$$\text{若 } x_1 + x_2 < 4 \Rightarrow \lambda_1 = 0 \Rightarrow x_1 = x_2 = 3$$

$$\Rightarrow x_1 + x_2 = 6 > 4 \Rightarrow \text{矛盾。}$$

$$\therefore x_1 + x_2 = 4 \Rightarrow x_1 = x_2 = 2 \Rightarrow \lambda_1 = 1$$

$$\therefore [2, 2]^T \text{ 为 K-T 点。}$$

$$\begin{cases} x_1 + \lambda_1 - \lambda_2 = 3 \\ x_2 + \lambda_1 - \lambda_3 = 3 \\ \lambda_1(x_1 + x_2 - 4) = 0 \\ -\lambda_2 x_1 = 0 \\ -\lambda_3 x_2 = 0 \\ x_1 + x_2 - 4 \leq 0 \\ \lambda_1, \lambda_2, \lambda_3, x_1, x_2 \geq 0 \end{cases}$$



大纲

- 约束极值及最优性条件
- 约束极值问题的算法



约束极值问题的算法

制约函数法（SUMT）

算法思想：

将有约束优化问题转化为一系列无约束优化问题进行求解。
(Sequential Unconstrained Minimization Technique - SUMT)

算法类型：

- 外点法（惩罚函数法）
- 内点法（障碍函数法）



矩阵计算与优化 (非线性规划-有约束优化)

不等式约束问题下, 外点法 (惩罚函数法) :

算法思想: 构造 $\phi_k(x)$

$$\varphi_k(x) \text{ 满足: } \varphi_k(x) = f(x) \quad x \in D$$

$$\varphi_k(x) > f(x) \quad x \notin D \text{ 且 } \varphi_k(x) \uparrow (k \uparrow)$$

$$\min_{x \in D} f(x) \Rightarrow \min_{x \in R^n} \varphi_1(x) \Rightarrow \min_{x \in R^n} \varphi_2(x) \Rightarrow \cdots \Rightarrow \min_{x \in R^n} \varphi_k(x)$$

$$\text{可取: } \varphi_k(x) = f(x) + \lambda_k p(x),$$

其中 $p(x)$ 满足条件:

$$(1) \quad p(x) = 0 \quad x \in D;$$

$$(2) \quad p(x) > 0 \quad x \notin D。$$

$$\lambda_1 < \lambda_2 < \cdots < \lambda_k (\uparrow) \rightarrow +\infty$$



如何构造 $p(x)$?

因为 $g_j(x) \leq 0 \Leftrightarrow \max\{g_j(x), 0\} = 0 \Leftrightarrow \max(\{g_j(x), 0\})^2 = 0$

所以可设

$$p(x) = \sum_{j=1}^m (\max\{g_j(x), 0\})^2 = \sum_{j=1}^m \max^2\{g_j(x), 0\}$$

显然 $p(x)$ 满足恰前面的条件 (1)和(2)。



矩阵计算与优化（非线性规划-有约束优化）

例：试用外点法（外部惩罚 函数法）求解如下优化 问题

$$\min f(x) = (x-1)^2$$

$$\text{s.t. } x-2 \geq 0$$

解：构造增广函数 $\varphi_k(x)$ 如下：

$$\varphi_k(x) = (x-1)^2 + \lambda_k \min(\{x-2, 0\})^2$$

$$= \begin{cases} (x-1)^2 & \text{if } x \geq 2 \\ (x-1)^2 + \lambda_k (x-2)^2 & \text{if } x < 2 \end{cases}$$

$$\frac{d\varphi_k(x)}{dx} = \begin{cases} 2(x-1) & \text{if } x \geq 2 \\ 2(x-1) + 2\lambda_k (x-2) & \text{if } x < 2 \end{cases}$$

$$\text{由 } \frac{d\varphi_k(x)}{dx} = 0 \text{ 可得：} 2(x-1) + 2\lambda_k (x-2) = 0$$




矩阵计算与优化 (非线性规划-有约束优化)

$$\text{所以 } x^k = x^*(\lambda_k) = \frac{1 + 2\lambda_k}{1 + \lambda_k}$$

这就是对于固定的 λ_k , 问题 $\min_{x \in R^n} \varphi_k(x)$ 的最优解。

$$\lim_{k \rightarrow \infty} x^k = \lim_{k \rightarrow \infty} x^*(\lambda_k) = \lim_{k \rightarrow \infty} \frac{1 + 2\lambda_k}{1 + \lambda_k} = 2 = x^*,$$

x^* 就是所求原问题的最优解。





矩阵计算与优化（非线性规划-有约束优化）

算法步骤（外点法）：

step1: 给定初始点 x^0 , 初始惩罚因子 $\lambda_1 > 0$ (可取 $\lambda_1 = 1$),
精度 $\varepsilon > 0, k := 0$ 。

step2: 以 x^k 为初始点, 求解无约束优化问题

$$\min_{x \in R^n} \varphi_k(x) = f(x) + \lambda_k p(x) = f(x) + \lambda_k \sum_{j=1}^m \max^2(g_j(x), 0)$$

得到极小点为 $x^*(\lambda_k)$, 记为 x^{k+1} 。

step 3: 如果 $x^*(\lambda_k) \in D$, 即 $\lambda_k p(x) \leq \varepsilon$,


则 $x^*(\lambda_k)$ 就是问题 (A) : $\min_{x \in D} f(x)$ 的最优解, stop;

否则转 step 4.

step 4: 给定 $\lambda_{k+1} > \lambda_k$ (可取 $\lambda_{k+1} = \alpha \lambda_k$ 这里 $\alpha > 1$ 为惩罚因子的放大系数), $k := k + 1$, 转 step 2.



外点法框图





矩阵计算与优化 (非线性规划-有约束优化)

应注意的问题

(a) 在step2中, 可用无约束优化问题的 算法求解

$$\min_{x \in R^n} \varphi_k(x) = f(x) + \lambda_k p(x)$$

(b) 在实际计算中, 判断 $x^*(\lambda_k) \in D$ 用 $|g_j(x^*(\lambda_k))| \geq \varepsilon$
($j = 1, 2, \dots, m$) 或 $\lambda_k p(x) < \varepsilon$.

(c) 在算法中, 一开始 λ_k 不宜取的过大。否则会 造成
无约束优化问题 $\min_{x \in R^n} \varphi_k(x)$ 求解困难 (λ_k 越大,
 $\varphi_k(x)$ 的Hesse矩阵的条件数越坏)。

(d) 通常称:

$\varphi_k(x)$: 增广函数, $p(x)$: 惩罚函数

λ_k : 惩罚因子, $\lambda_k p(x)$: 惩罚项



矩阵计算与优化（非线性规划-有约束优化）

一般约束问题下，外点法：

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & \begin{cases} g_i(x) \leq 0, & i = 1, \dots, m \\ h_j(x) = 0, & j = 1, \dots, p \end{cases} \end{array} \quad \Longleftrightarrow \quad \begin{array}{ll} \min & f(x) \\ \text{s.t.} & \begin{cases} g(x) \leq 0 \\ h(x) = 0 \end{cases} \end{array}$$

□ 我们不难想到构造如下的惩罚函数

$$\begin{aligned} p(x) &= \sum_{j=1}^m (\max\{g_j(x), 0\})^2 + \sum_{k=1}^l (h_k(x))^2 \\ &= \sum_{j=1}^m \max^2\{g_j(x), 0\} + \sum_{k=1}^l h_k^2(x) \end{aligned}$$

□ 算法步骤相同



算法收敛性

结论 1. 若点列 $\{x^k\}$ 是由外点法产生的, 则 有

$$\varphi_{k+1}(x^{k+1}) \geq \varphi_k(x^k)$$

$$p(x^{k+1}) \leq p(x^k)$$

$$f(x^{k+1}) \geq f(x^k)$$


结论 2. 设 $f(x)$ 、 $g_j(x)(j=1, \dots, m)$ 和 $h_k(x)(k=1, \dots, l)$ 都是 R^n 上的连续函数, 则由外点法产生的点列 $\{x^k\}$ 的任何极限点一定是所求问题的极小点。



矩阵计算与优化 (非线性规划-有约束优化)

内点法 (障碍函数法)

集合结构



$$D = \partial D \cup \text{int } D = \text{边界点集} \cup \text{内点集}$$

$$\partial D = \{x \mid \text{至少存在一个 } j, \text{ 使得 } g_j(x) = 0\};$$

$$\text{int } D = \{x \mid g_j(x) < 0, \forall j\}.$$



算法思想

内点法（障碍函数法）的迭代点是在可行域点集内部移动的，对接近可行域边界上的点施加越来越大的惩罚，对可行域边界上的点施加无限大的惩罚，这好比边界是一道障碍物，阻碍迭代点穿越边界。

内点法要求可行点集的内点集合非空，否则算法无法运行。这样一来内点法只对不等式约束的优化问题才可能有效。



算法分析

考虑如下优化问题:

$$\begin{aligned} \min & f(x) \\ \text{s.t. } & g_i(x) \leq 0, i = 1, \dots, m \end{aligned}$$

构造函数 $\psi_k(x) = f(x) + \mu_k q(x)$,

其中 $q(x)$ 满足:

- (1) $q(x) > 0$ if $x \in \text{int } D$
- (2) $q(x) \rightarrow +\infty$ if $x \rightarrow \partial D$

转化为无约束优化问题:

$$\min_{x \in R^n} \psi_k(x) = f(x) + \mu_k q(x)$$

$$\mu_1 > \mu_2 > \dots > \mu_k (\downarrow) \rightarrow 0$$



$q(x)$ 一般取以下形式的函数（常取前两种）

$$q(x) = \sum_{j=1}^m -\frac{1}{g_j(x)} \quad \text{或} \quad q(x) = \sum_{j=1}^m \frac{1}{g_j^2(x)} \text{ 等};$$

$$q(x) = \sum_{j=1}^m \ln \frac{1}{-g_j(x)} \quad \text{或} \quad q(x) = -\sum_{j=1}^m \ln(-g_j(x)) \text{ 等}。$$

通常称：

$\psi_k(x)$: 增广函数， $q(x)$: 障碍函数，

μ_k : 惩罚因子， $\mu_k q(x)$: 惩罚项。



矩阵计算与优化（非线性规划-有约束优化）

例 试用内点法（内部惩罚 函数法）求解如下优化 问题

$$\begin{aligned} \min f(x) &= \frac{1}{3}x^3 \\ \text{s.t. } x-1 &\geq 0 \end{aligned}$$

解 构造增广函数 $\psi_k(x)$ 如下：

$$\psi_k(x) = x^3 + \mu_k \frac{1}{x-1}$$

由 $\frac{d\psi_k(x)}{dx} = x^2 - \frac{\mu_k}{(x-1)^2} = 0$ 可得：

$$x(x-1) = \pm\sqrt{\mu_k}$$

因为 $x \geq 1$ 所以 $x(x-1) = \sqrt{\mu_k}$ 。




矩阵计算与优化 (非线性规划-有约束优化)

因此 $x = \frac{1}{2}(1 \pm \sqrt{1 + 4\sqrt{\mu_k}})$

因为负根不满足条件, 所以

$$x^{k+1} = \frac{1}{2}(1 + \sqrt{1 + 4\sqrt{\mu_k}})$$



由此可以得到:

$$x^* = \lim_{k \rightarrow \infty} x^{k+1} = \lim_{k \rightarrow \infty} \frac{1}{2}(1 + \sqrt{1 + 4\sqrt{\mu_k}}) = 1$$



矩阵计算与优化 (非线性规划-有约束优化)

算法步骤 (内点法) :

step1: 给定初始点 $x^0 \in \text{int } D$, 初始惩罚因子 $\mu_1 > 0$,

(可取 $\mu_1 = 1$), 精度 $\varepsilon > 0, k := 0$ 。

step2: 以 x^k 为初始点, 求解无约束 优化问题

$$\min_{x \in R^n} \psi_k(x) = f(x) + \mu_k q(x) = f(x) + \mu_k \sum_{j=1}^m \frac{1}{-g_j(x)}$$

得到其最优解 $x^*(\lambda_k)$, 记为 x^{k+1} 。


step 3: 如果 $\mu_k q(x^{k+1}) \leq \varepsilon$, 则 x^{k+1} 就是问题

(A) : $\min_{x \in D} f(x)$ 的最优解, stop; 否则转 step 4。

step 4: 给定 $\mu_{k+1} < \mu_k$ (可取 $\mu_{k+1} = \beta \mu_k$ 这里 $\beta < 1$ 为惩罚因子的缩小系数), $k := k + 1$, 转 step 2。



内点法框图





算法收敛性:

结论 1. 若点列 $\{x^k\}$ 是由内点法产生的, 则 有

$$\psi_{k+1}(x^{k+1}) \leq \psi_k(x^k)。$$

结论 2. 设 $f(x)$ 、 $g_j(x)(j=1, \dots, m)$ 都是 R^n 上的连续函数, 则由内点法 产生的点列 $\{x^k\}$ 的任何极限点一定是所 求问题的极小点。

制约函数法的缺点

1. 当外点法 (或内点法) 的 $\lambda \rightarrow +\infty$ ($\mu \rightarrow 0^+$) 时, 惩罚项 $\lambda_k p(x) \rightarrow +\infty \bullet 0$ (或 $\mu_k q(x) \rightarrow 0 \bullet +\infty$) 形式, 在计算上有困难;
2. 计算一系列无约束问题, 因而计算量大。



矩阵计算与优化（非线性规划-有约束优化）

内、外点法的优缺点的比较

外点法	内点法
1.任意 $x^{(0)} \in R^n$	1. $x^{(0)} \in S^0$
2.等式约束适用	2. 等式约束不适用
3.惩罚项的二阶偏导在 S 的边界上不存在	3. 障碍函数 $B(x)$ 在 S^0 的可微阶数与 $g_i(x)$ 相同(可选用的无约束最优化方法广)
4. 迭代中 $x^{(k)} \notin D$	4.迭代中 $x^{(k)} \in D$ （随时可取 $x^{(k)} \approx x^*$ ）
5. 非凸规划适用	5. 非凸规划适用



惩罚函数法的改进版本：乘子法

惩罚函数法的主要困难在于其辅助问题的最优解要达到对原问题解得较好近似，常常在罚因子的极限情况下才能实现。这在前面已做了讨论，其中主要因素之一，是在最优解 x^* ，目标函数的梯度 $\nabla f(x^*) \neq 0$ 。

那么如果用拉格朗日函数 L 取代 $f(x)$ 构造辅助问题，根据KT条件，在最优解 x^* ，存在最优乘子 v^* ，有 $\nabla_x L = 0$ 。这样就弥补了 $\nabla f(x^*) \neq 0$ 造成的困难，在这个思想下可得到乘子罚函数法，简称乘子法。



矩阵计算与优化 (非线性规划-有约束优化)

等式约束问题下，乘子法：

$$\text{等式约束} \quad \left\{ \begin{array}{ll} \min f(x) & f: R^n \rightarrow R \\ \text{s.t. } h(x) = 0 & h: R^n \rightarrow R^l \\ x \in D & D \subseteq R^n \text{ 是一个集合, 常由简单约束构成。} \end{array} \right.$$

用Lagrange函数代替 $f(x)$: $L(x, v) = f(x) + \sum_{i=1}^l v_i h_i(x)$

乘子罚函数：

$$\phi(x, v, \mu) = f(x) + \sum_{i=1}^l v_i h_i(x) + \sum_{i=1}^l \mu_i h_i^2(x)$$

其中： $v \in R^l$ 为乘子， $\mu \in R^l$ 为罚因子。

乘子罚函数与Lagrange函数及惩罚函数的区别：多一项。



乘子罚函数:

$$\phi(x, v, \mu) = f(x) + \sum_{i=1}^l v_i h_i(x) + \sum_{i=1}^l u_i h_i^2(x)$$

其中: $v \in R^l$ 为乘子, $u \in R^l$ 为罚因子。

$$\text{求解} \begin{cases} \min & \phi(x, v^{(k)}, u^{(k)}) \\ \text{s.t.} & x \in D \end{cases} \quad \text{得到 } x^{(k+1)}, k = 0, 1, 2, \dots$$

若 $h(x^{(k+1)}) = 0$ 得到解 $x^{(k+1)}$ 及乘子 $v^{(k)}$;

否则 调整 $v^{(k)}$ 及 $\mu^{(k)}$ 。



一般约束问题下，乘子法：

$$\left\{ \begin{array}{l} \min f(x) \\ \text{s.t. } g(x) \leq 0 \\ h(x) = 0 \\ x \in D \end{array} \right. \xrightarrow{\text{引入松弛变量}} \left\{ \begin{array}{l} \min f(x) \\ \text{s.t. } g(x) + z = 0 \\ h(x) = 0 \\ x \in D' = \left\{ \begin{pmatrix} x \\ z \end{pmatrix} \mid x \in D, z \geq 0 \right\} \end{array} \right.$$



矩阵计算与优化 (非线性规划-有约束优化)

例：问题 $\min \frac{1}{2}x_1^2 + \frac{1}{6}x_2^2$ 的最优解为 $x^* = (0.25, 0.75)$, 分别用惩罚函数法和乘子法求它的迭代点列。

s.t. $x_1 + x_2 = 1$

解：1. 惩罚函数法。对于惩罚函数

$$\psi(x) = \frac{1}{2}x_1^2 + \frac{1}{6}x_2^2 + u_k(x_1 + x_2 - 1)^2$$

可求得最优解为： $x^{k*} = \left(\frac{2u_k}{1+8u_k}, \frac{6u_k}{1+8u_k} \right)$

2. 乘子法。对于乘子罚函数

$$\phi(x) = \frac{1}{2}x_1^2 + \frac{1}{6}x_2^2 + v_k(x_1 + x_2 - 1) + u_k(x_1 + x_2 - 1)^2$$

可求得最优解为： $x^{k*} = \left(\frac{2u_k - v_k}{1+8u_k}, \frac{3(2u_k - v_k)}{1+8u_k} \right)$

取 $u_k = 0.05 \times 2^k$, $v_0 = 0$, $v_{k+1} = v_k + u_k(x_1^{(k)} + x_2^{(k)} - 1)$, $k \geq 1$, 得下表



矩阵计算与优化 (非线性规划-有约束优化)

k	x^{k*} (惩罚函数法)	x^k (乘子法)
0	(0.0714, 0.2142)	(0.0714, 0.2142)
1	(0.1111, 0.3333)	(0.1507, 0.4523)
2	(0.1538, 0.4615)	(0.2118, 0.6355)
3	(0.1904, 0.5714)	(0.2409, 0.7227)
4	(0.2162, 0.6486)	(0.2487, 0.7463)
5	(0.2318, 0.6956)	(0.2499, 0.7497)
6	(0.2406, 0.7218)	(0.2499, 0.7499)
7	(0.2452, 0.7356)	
8	(0.2475, 0.7427)	
9	(0.2487, 0.7463)	
10	(0.2492, 0.7481)	
11	(0.2496, 0.7490)	
12	(0.2498, 0.7495)	
13	(0.2499, 0.7497)	
14	(0.2499, 0.7498)	
15	(0.2499, 0.7499)	

从表中可见, x^{k*} 比 x^k 趋近 x^* 的速度慢得多, 用乘子法迭代6次就达到惩罚函数法迭代15次的效.

这里, 惩罚因子在惩罚函数法中要增大到 $u_{15} = 3276.8$, 而在乘子法中只要增大到 $u_6 = 6.4$.

相比之下, 乘子法不需过分地增大惩罚因子, 确实比惩罚函数法有效很多.



矩阵计算与优化 (非线性规划-有约束优化)

算法步骤 (乘子罚函数法) :

step1: 给定初始点 x^0 , 初始乘子向量 $v^{(1)}$, 初始罚因子 $u^{(1)}$
及其放大系数 $\alpha > 1$ (可取 $2 \leq \alpha \leq 10$), 常数 $r \in (0, 1)$,
精度 $\varepsilon > 0$, 令 $k := 1$ 。

step2: 以 x^{k-1} 为初始点, 求解无约束 优化问题

$$\min_{x \in R^n} \phi(x, v^{(k)}, u^{(k)}) = f(x) + \sum_{i=1}^l v_i^{(k)} h_i(x) + u^{(k)} \sum_{i=1}^l h_i^2(x)$$

得到其最优解 $x^*(u^{(k)}, v^{(k)})$, 记为 x^k 。

step 3: 如果 $\|h(x^k)\| \leq \varepsilon$, 则 x^k 就是最优解, stop; 否则, 计算

$\beta = \|h(x^k)\| / \|h(x^{k-1})\|$, 若 $\beta \leq r$, 转 step 4,

若 $\beta > r$, 令 $u^{(k+1)} = \alpha u^{(k)}$, 转 step 4.

step 4: 计算 $v_j^{(k+1)} = v_j^{(k)} + u^{(k)} h_j(x)$, $j = 1, 2, \dots, m$, $k := k + 1$,

转 step 2。



Presentation题目（5.27号3-4节）

1. 无约束优化方法的数值求解算法对比（构建场景）
2. 有约束优化方法的数值求解算法对比（构建场景）



感谢聆听!