

矩阵计算与优化

Matrix Computation and Optimization

吕月明

南京大学智能科学与技术学院



实验课 1

举 2 个例子

例 1: 条件数在判断复共线性中的应用

某国家 11 年的经济数据如表 1.1 所示, 其中三个自变量因子 X_1, X_2, X_3 分别表示 “ $X_1 =$ 国内总产值”, “ $X_2 =$ 存储量”, “ $X_3 =$ 总消费量”, 应变变量 “ $Y =$ 进口总额”, 考虑今后进口总额预测问题.

某国家 11 年的经济数据如表 1.1 所示, 其中三个自变量因子 X_1, X_2, X_3 分别表示 “ $X_1 =$ 国内总产值”, “ $X_2 =$ 存储量”, “ $X_3 =$ 总消费量”, 应变变量 “ $Y =$ 进口总额”, 考虑今后进口总额预测问题.

为此需要利用表 1.1 给出的数据, 用多元线性回归方法, 拟合出 Y 与 X_1, X_2, X_3 的关系, 再用该关系式预测 Y 的值. 这种方法是否可行呢?

表 1.1 经济数据

年	X_1	X_2	X_3
第 1 年	149.3	4.2	108.1
第 2 年	161.2	4.1	114.8
第 3 年	171.5	3.1	123.2
第 4 年	175.5	3.1	126.9
第 5 年	180.8	1.1	132.1
第 6 年	190.7	2.2	137.7
第 7 年	202.1	2.1	146.0
第 8 年	212.4	5.6	154.1
第 9 年	226.1	5.0	162.3
第 10 年	231.9	5.1	164.3
第 11 年	239.0	0.7	167.6

设有 p 个自变量 $x_1, x_2, \dots, x_p$, 以及 1 个应变量 y . 根据第 8.2 节的方法, 多元线性回归模型为

$$\begin{cases} y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon, \\ E(\varepsilon) = 0, \text{Var}(\varepsilon) = \sigma^2, \end{cases} \quad (1)$$

其中 $\beta_0, \beta_1, \dots, \beta_p$ 是 $p+1$ 个未知参数.

如果 $(x_1, x_2, \dots, x_p, y)$ 有 n 组观察值

$$(x_{i1}, x_{i2}, \dots, x_{ip}, y_i), i = 1, 2, \dots, n,$$

且观察数据已中心标准化, 则取 $\beta_0 = 0$.

如果 $(x_1, x_2, \dots, x_p, y)$ 有 n 组观察值

$$(x_{i1}, x_{i2}, \dots, x_{ip}, y_i), i = 1, 2, \dots, n,$$

且观察数据已中心标准化, 则取 $\beta_0 = 0$.

因此参数 $\beta_1, \beta_2, \dots, \beta_p$ 的最小二乘估计 $\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_p$ 就是如下问题的解

$$\min_{\beta_1, \beta_2, \dots, \beta_p} \sum_{i=1}^n [y_i - (\beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip})]^2$$

记

$$Y = \begin{pmatrix} y_1 \\ y_2 \\ \cdots \\ y_n \end{pmatrix}, X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

以及

$$\hat{\beta} = (\hat{\beta}_1, \hat{\beta}_2, \cdots, \hat{\beta}_p)^T.$$

记

$$Y = \begin{pmatrix} y_1 \\ y_2 \\ \cdots \\ y_n \end{pmatrix}, X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

以及

$$\hat{\beta} = (\hat{\beta}_1, \hat{\beta}_2, \cdots, \hat{\beta}_p)^T.$$

进而, y 的预测值为

$$\hat{y} = \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \cdots + \hat{\beta}_p x_p. \quad (2)$$

设 $X^T X$ 可逆, 则

$$\hat{\beta} = (X^T X)^{-1} X^T Y.$$

设 $X^T X$ 可逆, 则

$$\hat{\beta} = (X^T X)^{-1} X^T Y.$$

用均方误差 E_{ms} 来度量这个估计的好坏, 即有

$$E_{ms}(\hat{\beta}) = \sigma^2 \text{tr}(X^T X)^{-1}.$$

设对称矩阵 $X^T X$ 的特征值为 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p > 0$, 则 $(X^T X)^{-1}$ 的特征值为 $\lambda_1^{-1} \leq \lambda_2^{-1} \leq \cdots \leq \lambda_p^{-1}$.

设对称矩阵 $X^T X$ 的特征值为 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p > 0$, 则 $(X^T X)^{-1}$ 的特征值为 $\lambda_1^{-1} \leq \lambda_2^{-1} \leq \cdots \leq \lambda_p^{-1}$. 从而

$$E_{ms}(\hat{\beta}) = \sigma^2 \sum_{i=1}^p \lambda_i^{-1}.$$

设对称矩阵 $X^T X$ 的特征值为 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p > 0$, 则 $(X^T X)^{-1}$ 的特征值为 $\lambda_1^{-1} \leq \lambda_2^{-1} \leq \cdots \leq \lambda_p^{-1}$. 从而

$$E_{ms}(\hat{\beta}) = \sigma^2 \sum_{i=1}^p \lambda_i^{-1}.$$

如果 λ_p 较小, 则条件数 $\text{cond}(X^T X)$ 较大, 反之亦然.

设对称矩阵 $X^T X$ 的特征值为 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p > 0$, 则 $(X^T X)^{-1}$ 的特征值为 $\lambda_1^{-1} \leq \lambda_2^{-1} \leq \cdots \leq \lambda_p^{-1}$. 从而

$$E_{ms}(\hat{\beta}) = \sigma^2 \sum_{i=1}^p \lambda_i^{-1}.$$

如果 λ_p 较小, 则条件数 $\text{cond}(X^T X)$ 较大, 反之亦然. 此时 $E_{ms}(\hat{\beta})$ 较大, 说明最小二乘估计 $\hat{\beta}$ 是坏的, 会导致由 (2) 得到的预测值 $\hat{y}$ 有较大的误差.

对特征值 λ_p , 存在单位特征向量 $z_p = (z_{p1}, z_{p2}, \dots, z_{pp})^T$, 使得 $X^T X z_p = \lambda_p z_p$.

对特征值 λ_p , 存在单位特征向量 $z_p = (z_{p1}, z_{p2}, \dots, z_{pp})^T$, 使得 $X^T X z_p = \lambda_p z_p$.

两边左乘 z_p^T , 得 $z_p^T X^T X z_p = z_p^T \lambda_p z_p$, 即 $(X z_p)^T X z_p = \lambda_p$.

对特征值 λ_p , 存在单位特征向量 $z_p = (z_{p1}, z_{p2}, \dots, z_{pp})^T$, 使得 $X^T X z_p = \lambda_p z_p$.

两边左乘 z_p^T , 得 $z_p^T X^T X z_p = z_p^T \lambda_p z_p$, 即 $(X z_p)^T X z_p = \lambda_p$. 如果 $\lambda_p \approx 0$, 则 $X z_p \approx 0$. 记 $X = (X_1, X_2, \dots, X_p)$, 则有

$$z_{p1} X_1 + z_{p2} X_2 + \dots + z_{pp} X_p \approx 0. \quad (3)$$

对特征值 λ_p , 存在单位特征向量 $z_p = (z_{p1}, z_{p2}, \dots, z_{pp})^T$, 使得 $X^T X z_p = \lambda_p z_p$.

两边左乘 z_p^T , 得 $z_p^T X^T X z_p = z_p^T \lambda_p z_p$, 即 $(X z_p)^T X z_p = \lambda_p$. 如果 $\lambda_p \approx 0$, 则 $X z_p \approx 0$. 记 $X = (X_1, X_2, \dots, X_p)$, 则有

$$z_{p1} X_1 + z_{p2} X_2 + \dots + z_{pp} X_p \approx 0. \quad (3)$$

式 (3) 说明 X 的列向量 $X_1, X_2, \dots, X_p$ 近似于线性相关, 称它们有复共线性关系, 称线性回归模型 (1) 存在复共线性.

最小二乘估计 $\hat{\beta}$ 变坏是由模型 (1) 的复共线性导致的, 而条件数 $\text{cond}(X^T X)$ 的大小可以用来说明 X 的列向量复共线性的强度.

最小二乘估计 $\hat{\beta}$ 变坏是由模型 (1) 的复共线性导致的, 而条件数 $\text{cond}(X^T X)$ 的大小可以用来说明 X 的列向量复共线性的强度. 一般地, 当 $0 < \text{cond}(X^T X) \leq 30$ 时, 认为 X 的列向量没有复共线性;

最小二乘估计 $\hat{\beta}$ 变坏是由模型 (1) 的复共线性导致的, 而条件数 $\text{cond}(X^T X)$ 的大小可以用来说明 X 的列向量复共线性的强度. 一般地, 当 $0 < \text{cond}(X^T X) \leq 30$ 时, 认为 X 的列向量没有复共线性;
当 $30 < \text{cond}(X^T X) \leq 100$ 时, 认为 X 的列向量有较弱的复共线性;

最小二乘估计 $\hat{\beta}$ 变坏是由模型 (1) 的复共线性导致的, 而条件数 $\text{cond}(X^T X)$ 的大小可以用来说明 X 的列向量复共线性的强度.

一般地, 当 $0 < \text{cond}(X^T X) \leq 30$ 时, 认为 X 的列向量没有复共线性;

当 $30 < \text{cond}(X^T X) \leq 100$ 时, 认为 X 的列向量有较弱的复共线性;

当 $100 < \text{cond}(X^T X) \leq 1000$ 时, 认为 X 的列向量有中等或较强的复共线性;

最小二乘估计 $\hat{\beta}$ 变坏是由模型 (1) 的复共线性导致的, 而条件数 $\text{cond}(X^T X)$ 的大小可以用来说明 X 的列向量复共线性的强度.

一般地, 当 $0 < \text{cond}(X^T X) \leq 30$ 时, 认为 X 的列向量没有复共线性;

当 $30 < \text{cond}(X^T X) \leq 100$ 时, 认为 X 的列向量有较弱的复共线性;

当 $100 < \text{cond}(X^T X) \leq 1000$ 时, 认为 X 的列向量有中等或较强的复共线性;

当 $\text{cond}(X^T X) > 1000$ 时, 认为 X 的列向量有最严重的复共线性.

若用线性回归模型 (1) 拟合给定的数据, 需要选择没有复共线性的因子 $X_1, X_2, \dots, X_p$, 这样由 (2) 获取的 y 的预测值才有更高的准确度.

针对表 1.1 给出的经济数据, 将因子向量 X_1, X_2, X_3 的数据中心化, 即 X_i 的每个数据减去 X_i 所有数据的平均值 ($i=1,2,3$), 所得结果列于表 1.2 的左侧.

针对表 1.1 给出的经济数据, 将因子向量 X_1, X_2, X_3 的数据中心化, 即 X_i 的每个数据减去 X_i 所有数据的平均值 ($i=1,2,3$), 所得结果列于表 1.2 的左侧.

然后再将其标准化, 即将表 1.2 左侧 X_i 的每个数据除以 X_i 的 2 范数 ($i=1,2,3$), 所得结果列于表 1.2 的右侧.

针对表 1.1 给出的经济数据, 将因子向量 X_1, X_2, X_3 的数据中心化, 即 X_i 的每个数据减去 X_i 所有数据的平均值 ($i=1,2,3$), 所得结果列于表 1.2 的左侧.

然后再将其标准化, 即将表 1.2 左侧 X_i 的每个数据除以 X_i 的 2 范数 ($i=1,2,3$), 所得结果列于表 1.2 的右侧.

将中心化及标准化的数据, 即表 1.2 右侧的数据, 仍记为 X_1, X_2, X_3 , 而 $X = (X_1, X_2, X_3)$.

表 1.2 中心及标准化数据

X_1	X_2	X_3	$X_1/\ X_1\ _2$	$X_2/\ X_2\ _2$	$X_3/\ X_3\ _2$
-45.290909	0.900000	-31.636364	-0.477416	0.172567	-0.484836
-33.390909	0.800000	-24.936364	-0.351977	0.153393	-0.382156
-23.090909	-0.200000	-16.536364	-0.243403	-0.038348	-0.253424
-19.090909	-0.200000	-12.836364	-0.201239	-0.038348	-0.196721
-13.790909	-2.200000	-7.636364	-0.145371	-0.421831	-0.117029
-3.890909	-1.100000	-2.036364	-0.041014	-0.210915	-0.031208
7.509091	-1.200000	6.263636	0.079154	-0.230089	0.095992
17.809091	2.300000	14.363636	0.187727	0.441005	0.220127
31.509091	1.700000	22.563636	0.332140	0.325960	0.345794
37.309091	1.800000	24.563636	0.393279	0.345134	0.376444
44.409091	-2.600000	27.863636	0.468120	-0.498527	0.427018

则有

$$X^T X = \begin{pmatrix} 1.000000 & 0.025851 & 0.997261 \\ 0.025851 & 1.000000 & 0.035673 \\ 0.997261 & 0.035673 & 1.000000 \end{pmatrix}.$$

则有

$$X^T X = \begin{pmatrix} 1.000000 & 0.025851 & 0.997261 \\ 0.025851 & 1.000000 & 0.035673 \\ 0.997261 & 0.035673 & 1.000000 \end{pmatrix}.$$

那么经过计算易获得 $X^T X$ 的特征值

为: $\lambda_1 = 1.999155, \lambda_2 = 0.998154, \lambda_3 = 0.002691$.

则有

$$X^T X = \begin{pmatrix} 1.000000 & 0.025851 & 0.997261 \\ 0.025851 & 1.000000 & 0.035673 \\ 0.997261 & 0.035673 & 1.000000 \end{pmatrix}.$$

那么经过计算易获得 $X^T X$ 的特征值

为: $\lambda_1 = 1.999155, \lambda_2 = 0.998154, \lambda_3 = 0.002691$.

从而条件数

$$\text{cond}(X^T X) = \lambda_1 / \lambda_3 = 742.9.$$

则有

$$X^T X = \begin{pmatrix} 1.000000 & 0.025851 & 0.997261 \\ 0.025851 & 1.000000 & 0.035673 \\ 0.997261 & 0.035673 & 1.000000 \end{pmatrix}.$$

那么经过计算易获得 $X^T X$ 的特征值

为: $\lambda_1 = 1.999155, \lambda_2 = 0.998154, \lambda_3 = 0.002691$.

从而条件数

$$\text{cond}(X^T X) = \lambda_1 / \lambda_3 = 742.9.$$

故, 因子 X_1, X_2, X_3 存在较强的复共线性.

则有

$$X^T X = \begin{pmatrix} 1.000000 & 0.025851 & 0.997261 \\ 0.025851 & 1.000000 & 0.035673 \\ 0.997261 & 0.035673 & 1.000000 \end{pmatrix}.$$

那么经过计算易获得 $X^T X$ 的特征值

为: $\lambda_1 = 1.999155, \lambda_2 = 0.998154, \lambda_3 = 0.002691$.

从而条件数


$$\text{cond}(X^T X) = \lambda_1 / \lambda_3 = 742.9.$$

故, 因子 X_1, X_2, X_3 存在较强的复共线性.

所以, 用 Y 与 X_1, X_2, X_3 的线性回归模型预测进口额准确度不高.

例 2: 盖尔圆定理在混沌系统同步控制中的应用

考虑 Chua 电路, 如图所示:



Chua 电路图

Chua 电路系统状态方程为:

$$\begin{cases} \frac{dv_1}{dt} = \frac{1}{C_1} [G(v_2 - v_1) - f_{N_R}(v_1)] \\ \frac{dv_2}{dt} = \frac{1}{C_2} [G(v_1 - v_2) + i_3] \\ \frac{di_3}{dt} = -\frac{1}{L} v_2 \end{cases} \quad (1)$$

Chua 电路系统状态方程为:

$$\begin{cases} \frac{dv_1}{dt} = \frac{1}{C_1} [G(v_2 - v_1) - f_{N_R}(v_1)] \\ \frac{dv_2}{dt} = \frac{1}{C_2} [G(v_1 - v_2) + i_3] \\ \frac{di_3}{dt} = -\frac{1}{L} v_2 \end{cases} \quad (1)$$

其中, v_1 和 v_2 分别为电容 C_1 和 C_2 的电压, i_3 为通过电感 L 的电流, $G = \frac{1}{B}$ 是线性电阻器的电导.

Chua 电路系统状态方程为:

$$\begin{cases} \frac{dv_1}{dt} = \frac{1}{C_1} [G(v_2 - v_1) - f_{N_R}(v_1)] \\ \frac{dv_2}{dt} = \frac{1}{C_2} [G(v_1 - v_2) + i_3] \\ \frac{di_3}{dt} = -\frac{1}{L} v_2 \end{cases} \quad (1)$$

其中, v_1 和 v_2 分别为电容 C_1 和 C_2 的电压, i_3 为通过电感 L 的电流, $G = \frac{1}{B}$ 是线性电阻器的电导. 非线性函数 $f_{N_R}(v_1)$ 表示非线性电阻 N_R 的 $v-i$ 特性, 是分段线性函数,

Chua 电路系统状态方程为:


$$\begin{cases} \frac{dv_1}{dt} = \frac{1}{C_1} [G(v_2 - v_1) - f_{N_R}(v_1)] \\ \frac{dv_2}{dt} = \frac{1}{C_2} [G(v_1 - v_2) + i_3] \\ \frac{di_3}{dt} = -\frac{1}{L} v_2 \end{cases} \quad (1)$$

其中, v_1 和 v_2 分别为电容 C_1 和 C_2 的电压, i_3 为通过电感 L 的电流, $G = \frac{1}{R}$ 是线性电阻器的电导. 非线性函数 $f_{N_R}(v_1)$ 表示非线性电阻 N_R 的 $v-i$ 特性, 是分段线性函数, 其表达式为:

$$f_{N_R}(v_1) = G_b v_1 + \frac{1}{2} (G_a - G_b) (|v_1 + E| - |v_1 - E|)$$

式中 G_a, G_b 以及 E 为由元件特性决定的常数.

设 $C_1 = 10\text{nF}$, $C_2 = 90\text{nF}$, $R = 1.45\text{k}\Omega$,
 $L = 13\text{mH}$, $G_a = -0.7882\text{mS}$, $G_b = -0.4926\text{mS}$, $E = 1\text{V}$, 这时
Chua 电路系统 (1) 是混沌的, 其动态混沌吸引子如下图所示。



Chua 电路的混沌吸引子

Chua 系统 (1) 的从属系统为

$$\begin{cases} \frac{d\tilde{v}_1}{dt} = \frac{1}{C_1} (G(\tilde{v}_2 - \tilde{v}_1) - f_{N_R}(\tilde{v}_1)) + k_1(v_1 - \tilde{v}_1) \\ \frac{d\tilde{v}_2}{dt} = \frac{1}{C_2} (G(\tilde{v}_1 - \tilde{v}_2) + \tilde{i}_3) + k_2(v_2 - \tilde{v}_2) \\ \frac{d\tilde{i}_3}{dt} = -\frac{1}{L}\tilde{v}_2 + k_3(i_3 - \tilde{i}_3) \end{cases} \quad (2)$$

其中 $k_i \in \mathbb{R}$, $i = 1, 2, 3$

令同步误差

$$e(t) = \begin{pmatrix} v_1 - \tilde{v}_1 \\ v_2 - \tilde{v}_2 \\ i_3 - \tilde{i}_3 \end{pmatrix} = \begin{pmatrix} e_1 \\ e_2 \\ e_3 \end{pmatrix}$$

则由 (1) 和 (2), 得

$$\frac{de(t)}{dt} = Ae(t) + h(v(t)) - h(\tilde{v}(t)) - Ke(t),$$

其中

$$h(v(t)) = \begin{pmatrix} -\frac{1}{C_1} f_{NR}(v_1) \\ 0 \\ 0 \end{pmatrix}, A = \begin{pmatrix} -\frac{G}{C_1} & \frac{G}{C_1} & 0 \\ \frac{G}{C_2} & -\frac{G}{C_2} & \frac{1}{C_2} \\ 0 & -\frac{1}{L} & 0 \end{pmatrix}, K = \begin{pmatrix} k_1 & 0 & 0 \\ 0 & k_2 & 0 \\ 0 & 0 & k_3 \end{pmatrix}$$

另外, 我们有

$$\begin{aligned}\mathbf{h}(\mathbf{v}(t)) - \mathbf{h}(\tilde{\mathbf{v}}(t)) &= \begin{pmatrix} -\frac{1}{C_1} (\mathbf{f}_{N_R}(\mathbf{v}_1) - \mathbf{f}_{N_R}(\tilde{\mathbf{v}}_1)) \\ 0 \\ 0 \end{pmatrix} \\ &= \begin{pmatrix} -\frac{1}{C_1} k_{v_1, \tilde{v}_1} & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} v_1 - \tilde{v}_1 \\ v_2 - \tilde{v}_2 \\ i_3 - \tilde{i}_3 \end{pmatrix} = M_{v_1, \tilde{v}_1} \mathbf{e}\end{aligned}$$

这里 $k_{v_1, \tilde{v}_1}$ 与 v_1 和 $\tilde{v}_1$ 有关, 且满足

$$G_a \leq k_{v_1, \tilde{v}_1} \leq G_b < 0.$$

于是

$$\begin{aligned}
 A + M_{v_1, \tilde{v}_1} &= \begin{pmatrix} -\frac{1}{C_1} & (G + k_{v_1, \tilde{v}_1}) & \frac{G}{C_1} & 0 \\ & \frac{G}{C_2} & -\frac{G}{C_2} & 1 \\ & & -\frac{1}{L} & 0 \\ & & 0 & -\frac{1}{L} \end{pmatrix}, \\
 & (A + M_{v_1, \tilde{v}_1}) + (A + M_{v_1, \tilde{v}_1})^T \\
 &= \begin{pmatrix} -\frac{2}{C_1} (G + k_{v_1, \tilde{v}_1}) & \frac{G}{C_1} + \frac{G}{C_2} & 0 \\ \frac{G}{C_1} + \frac{G}{C_2} & -\frac{2G}{C_2} & \frac{1}{C_2} - \frac{1}{L} \\ 0 & \frac{1}{C_2} - \frac{1}{L} & 0 \end{pmatrix} \\
 &=: (\bar{a}_{ij}) .
 \end{aligned}$$

则有

$$\begin{aligned} & (A - K + M_{v_1, \tilde{v}_1}) + (A - K + M_{v_1, \tilde{v}_1})^T \\ &= (\bar{\mathbf{a}}_{ij}) - 2 \operatorname{diag}(k_1, k_2, k_3). \end{aligned}$$

则有

$$\begin{aligned} & (A - K + M_{v_1, \tilde{v}_1}) + (A - K + M_{v_1, \tilde{v}_1})^T \\ &= (\bar{a}_{ij}) - 2 \operatorname{diag}(k_1, k_2, k_3). \end{aligned}$$

所以, 矩阵 $(A - K + M_{v_1, \tilde{v}_1}) + (A - K + M_{v_1, \tilde{v}_1})^T$ 的第 i 个盖尔圆为

$$G_i : |z - (\bar{a}_{ii} - 2k_i)| \leq R_i,$$

$$\text{其中 } R_i = \sum_{\substack{j=1 \\ j \neq i}}^3 |\bar{a}_{ij}|.$$

又矩阵 $(\mathbf{A} - \mathbf{K} + \mathbf{M}_{v_1, \tilde{v}_1}) + (\mathbf{A} - \mathbf{K} + \mathbf{M}_{v_1, \tilde{v}_1})^T$ 的特征值为实数, 可得

$$z \leq \bar{a}_{ii} - 2k_i + R_i.$$

又矩阵 $(\mathbf{A} - \mathbf{K} + \mathbf{M}_{v_1, \tilde{v}_1}) + (\mathbf{A} - \mathbf{K} + \mathbf{M}_{v_1, \tilde{v}_1})^T$ 的特征值为实数, 可得

$$z \leq \bar{a}_{ii} - 2k_i + R_i.$$

再令

$$\bar{a}_{ii} - 2k_i + R_i \leq \mu < 0,$$

进而有

$$k_i \geq \frac{1}{2} (\bar{a}_{ii} + R_i - \mu).$$

由此, 如果

$$k_1 \geq \frac{1}{2} (\bar{a}_{11} + R_1 - \mu) = \frac{1}{2} \left(-\frac{2}{C_1} (G + k_{v_1, \tilde{v}_1}) + \left| \frac{G}{C_1} + \frac{G}{C_2} \right| - \mu \right),$$

$$k_2 \geq \frac{1}{2} (\bar{a}_{22} + R_2 - \mu) = \frac{1}{2} \left(-\frac{2G}{C_2} + \left| \frac{G}{C_1} + \frac{G}{C_2} \right| + \left| \frac{1}{C_2} - \frac{1}{L} \right| - \mu \right),$$

$$k_3 \geq \frac{1}{2} (\bar{a}_{33} + R_3 - \mu) = \frac{1}{2} \left(\left| \frac{1}{C_2} - \frac{1}{L} \right| - \mu \right),$$

则混沌系统 (1) 和 (2) 是全局渐近同步的.

取 $\mu = -0.5$, 可有

$$\begin{aligned} & \frac{1}{2} \left(-\frac{2}{C_1} (G + k_{v_1, \tilde{v}_1}) + \left| \frac{G}{C_1} + \frac{G}{C_2} \right| - \mu \right) \\ & \leq \frac{1}{2} \left(-\frac{2}{C_1} (G + G_a) + \left| \frac{G}{C_1} + \frac{G}{C_2} \right| - \mu \right) = 0.2982, \end{aligned}$$

取 $\mu = -0.5$, 可有

$$\begin{aligned} & \frac{1}{2} \left(-\frac{2}{C_1} (G + k_{v_1, \tilde{v}_1}) + \left| \frac{G}{C_1} + \frac{G}{C_2} \right| - \mu \right) \\ & \leq \frac{1}{2} \left(-\frac{2}{C_1} (G + G_a) + \left| \frac{G}{C_1} + \frac{G}{C_2} \right| - \mu \right) = 0.2982, \end{aligned}$$

$$\begin{aligned} & \frac{1}{2} \left(-\frac{2G}{C_2} + \left| \frac{G}{C_1} + \frac{G}{C_2} \right| + \left| \frac{1}{C_2} - \frac{1}{L} \right| - \mu \right) \\ & = \frac{1}{2} \left(\frac{G}{C_1} - \frac{1}{C_2} (G + 1) + \frac{1}{L} - \mu \right) = 0.3136, \end{aligned}$$

取 $\mu = -0.5$, 可有


$$\begin{aligned} & \frac{1}{2} \left(-\frac{2}{C_1} (G + k_{v_1, \tilde{v}_1}) + \left| \frac{G}{C_1} + \frac{G}{C_2} \right| - \mu \right) \\ & \leq \frac{1}{2} \left(-\frac{2}{C_1} (G + G_a) + \left| \frac{G}{C_1} + \frac{G}{C_2} \right| - \mu \right) = 0.2982, \end{aligned}$$

$$\begin{aligned} & \frac{1}{2} \left(-\frac{2G}{C_2} + \left| \frac{G}{C_1} + \frac{G}{C_2} \right| + \left| \frac{1}{C_2} - \frac{1}{L} \right| - \mu \right) \\ & = \frac{1}{2} \left(\frac{G}{C_1} - \frac{1}{C_2} (G + 1) + \frac{1}{L} - \mu \right) = 0.3136, \\ & \quad \frac{1}{2} \left(\left| \frac{1}{C_2} - \frac{1}{L} \right| - \mu \right) \\ & = \frac{1}{2} \left(\frac{1}{L} - \frac{1}{C_2} - \mu \right) = 0.2829. \end{aligned}$$


于是, 我们可取 $k_1 = 0.30, k_2 = 0.32, k_3 = 0.29$. 系统 (1) 和 (2) 同步总误差定义为

$$E(t) = \sqrt{\mathbf{e}^T \mathbf{e}} = \sqrt{(v_1 - \tilde{v}_1)^2 + (v_2 - \tilde{v}_2)^2 + (i_3 - \tilde{i}_3)^2}.$$


数值模拟结果见下图所示. 从这些图不难看出, 借助盖尔圆定理所给出的混沌系统的同步控制方案是有效的.




v_1 (实线), $\tilde{v}_1$ (虚线)的状态轨线



v_2 (实线), $\tilde{v}_2$ (虚线)的状态轨线



i_3 (实线), $\tilde{i}_3$ (虚线)的状态轨线



系统(1)和(2)同步总误差 E

题目

题目 1：机器学习正则化中的范数应用

对应知识点：向量范数、矩阵范数、范数等价性

场景背景（如金融风控、医疗特征建模）：线性回归 L1/L2 正则化，特征矩阵 $X \in \mathbb{R}^{m \times n}$ ，标签 y ，参数 β 。

$$J_1(\beta) = \frac{1}{2m} \|X\beta - y\|_2^2 + \lambda \|\beta\|_1$$

$$J_2(\beta) = \frac{1}{2m} \|X\beta - y\|_2^2 + \lambda \|\beta\|_2^2$$

解题角度：

- ① 解释范数意义，说明稀疏性差异
- ② 证明有限维空间范数等价性
- ③ 数值实验对比两种正则化
- ④ 分析 F 范数的数值稳定性优势

题目 2：神经网络训练中的收敛性分析

对应知识点：谱半径、收敛矩阵、矩阵级数、F 范数

场景背景（深度学习训练）：神经网络反向传播为迭代优化过程，迭代不收敛会导致权重震荡、无法得到最优解。权重迭代公式：

$$W_{t+1} = W_t - \eta \nabla L(W_t)$$

解题角度：

- ① 推导迭代收敛形式
- ② 证明收敛充要条件（谱半径小于 1）
- ③ 计算学习率收敛范围并验证
- ④ 结合矩阵级数说明解的合理性

题目 3：传感器网络数据传输优化

对应知识点：矩阵条件数、病态/良态矩阵、误差分析

场景背景（物联网信号传输）：传感器网络节点信号传输建模为线性方程组，噪声引发矩阵/信号扰动，易导致原始信号解失真。
传输模型：

$$Ax = b$$

解题角度：

- ① 推导解的相对误差公式
- ② 计算谱条件数并判断矩阵性态
- ③ 分析病态矩阵的噪声敏感特性
- ④ 设计预处理方案优化条件数

评分标准

评分维度	分值	评分要点
应用理解	15 分	应用理解准确，设计准确
知识点掌握	25 分	准确关联，定理/公式应用正确
解题逻辑	30 分	步骤清晰，推导严谨，可视化好
表达与互动	20 分	语言流畅，分工明确，控时精准
幻灯片质量	10 分	结构清晰，重点突出，排版规范

其他要求

- 每组 5-7 位同学
- 禁止组间互相抄袭
- 助教群里发提交链接
- PPT 一页：成员贡献说明
- 最终筛选 10 组左右进行课堂展示，10 分钟