



矩阵计算与优化

(最优化--多目标与随机优化)

智能科学与技术学院
吕月明



南京大學
NANJING UNIVERSITY



大纲

- 多目标优化
- 随机优化



多目标规划是数学规划的一个分支。

研究**多于一个的目标函数**在**给定区域**上的最优化。又称多目标最优化。通常记为 MOP(multi-objective programming)。

在很多实际问题中，例如经济、管理、军事、科学和工程设计等领域，**衡量一个方案的好坏往往难以用一个指标来判断**，而需要用多个目标来比较，而这些目标有时不甚协调，甚至是矛盾的。因此有许多学者致力于这方面的研究。

1896年法国**经济学家 V. 帕雷托**最早研究不可比较目标的优化问题，之后，J.冯·诺伊曼、H.W.库恩、A.W.塔克、A.M.日夫里翁等**数学家做了深入的探讨**，但是**尚未有一个完全令人满意的定义**。



多目标决策简介


一、多目标决策问题实例

- 购买手机—价格、性能、续航、品牌等
- 球员选择—技术、体能、经验、心理等
- 找工作—薪资、发展空间、工作地点、工作强度等



多目标决策简介

二、多目标决策与多目标规划





多目标决策简介

三、多目标决策与单目标决策区别

- **点评价与向量评价**

单目标：方案 $d_j \leftarrow$ 评价值 $f(d_j)$

多目标：方案 $d_j \leftarrow$ 评价向量 $(f_1(d_j), f_2(d_j), \dots, f_p(d_j))$

- **全序与半序：** 方案 d_i 与 d_j 之间

单目标问题： $d_i < d_j$; $d_i = d_j$; $d_i > d_j$

多目标问题：除了这三种情况之外,还有一种情况是不可比较大小（半序）

- **决策者偏好：** 多目标决策过程中，反映决策者对目标的偏好。



• 解概念区别

单目标决策的解只有一种（绝对）最优解；

多目标决策的解有下面三种情况：

➤ 绝对最优解

	数学	外语	专业	解的类型
d_1	80	75	88	
d_2	75	81	85	
d_3	76	78	89	
d_4	85	82	92	绝对最优解
d_5	78	74	86	



• 解概念区别

单目标决策的解只有一种（绝对）最优解；

多目标决策的解主要有下面三种情况：

- 绝对最优解
- 劣解（如 d_4 劣于 d_1 ）
- 有效解(pareto解)——非劣解

	数学	外语	专业	解的类型
d_1	80	75	88	有效解
d_2	75	81	85	有效解
d_3	76	78	89	有效解
d_4	78	74	86	劣解



多目标规划模型及其解的概念

一、多目标规划举例

例1：【喜糖问题】 设市场上有甲级糖及乙级糖，单价分别为4元/斤及2元/斤。今要筹办一桩喜事。“筹备小组”计划总花费不超过40元，糖的总斤数不少于10斤，甲级糖不少于5斤。问如何确定最佳的采购方案。

决策变量： 甲级糖数量为 x_1 ，乙级糖数量为 x_2

约束条件：

$$\begin{cases} 4x_1 + 2x_2 \leq 40 \\ x_1 + x_2 \geq 10 \\ x_1 \geq 5 \\ x_1 \geq 0, x_2 \geq 0 \end{cases}$$




多目标规划模型及其解的概念

目标函数：何为最佳？

(1) 总花费最小： $\min f_1(x_1, x_2)=4x_1+2x_2$

(2) 糖的总数量最大： $\max f_2(x_1, x_2)=x_1+x_2$

(3) 甲级糖的数量最大： $\max f_3(x_1, x_2)=x_1$



多目标规划问题



多目标规划模型及其解的概念

例2【投资决策问题】 某投资开发公司拥有总资金 A 万元，今有 $n(\geq 2)$ 个项目可供选择。设投资第 i ($i=1, \dots, n$) 个项目要用资金 a_i 万元，预计可得到收益 b_i 万元。问应如何使用总资金 A 万元，才能得到最佳的经济效益？

解：令

$$x_i = \begin{cases} 1, & \text{投资第} i \text{个项目} \\ 0, & \text{不投资第} i \text{个项目} \end{cases}$$

约束条件：

$$\begin{cases} \sum_{i=1}^n a_i x_i \leq A \\ x_i = 0 \text{ 或 } 1 (i = 1, \dots, n) \end{cases}$$



多目标规划模型及其解的概念

目标函数：何为最佳的经济效益？

(1) 收益最大：

$$\max f_1(x_1, \dots, x_n) = \sum_{i=1}^n b_i x_i$$

(2) 投资最少：

$$\min f_2(x_1, \dots, x_n) = \sum_{i=1}^n a_i x_i$$



多目标0-1规划问题（多准则决策、整数规划）



多目标规划模型及其解的概念

二、多目标规划的模型

决策变量: $x_1, \dots, x_n$

目标函数: $\min f_1(x_1, \dots, x_n)$
 $\dots$
 $\min f_p(x_1, \dots, x_n)$

约束条件:
$$\begin{cases} g_1(x_1, \dots, x_n) \geq 0 \\ \dots \\ g_m(x_1, \dots, x_n) \geq 0 \end{cases}$$



多目标规划模型及其解的概念

多目标规划模型的向量表达形式

记: $X = (x_1, \dots, x_n)^T$

$$F(X) = (f_1(X), \dots, f_p(X))^T$$

$$R = \{X \mid g_i(X) \geq 0, \quad i = 1, \dots, m\}$$

则模型为:

$$(VMP) \begin{cases} \min (f_1(X), \dots, f_p(X)) \\ g_i(X) \geq 0, \quad i = 1, \dots, m \end{cases}$$

向量数学规划
(Vector
Mathematical
Programming)

或

$$(VMP) \begin{cases} \min F(X) \\ X \in R \end{cases}$$



多目标规划模型及其解的概念

- 一、多目标规划举例
- 二、多目标规划的模型
- 三、多目标规划解的概念



多目标规划模型及其解的概念

三、多目标规划解的概念

先引进一些记号, 记

$$F^1 = (f_1^1, \dots, f_p^1) \in E_p$$

$$F^2 = (f_1^2, \dots, f_p^2) \in E_p$$

(1) " $<$ ": $F^1 < F^2$ 意味着向量 F^1 的每个分量都要严格的小于向量 F^2 对应的分量。即对于 $i = 1, \dots, p$, 均有 $f_i^1 < f_i^2$ 。

(2) " $\leq$ ": $F^1 \leq F^2$ 意味着向量 F^1 的每个分量都要小于或等于向量 F^2 对应的分量。即对于 $i = 1, \dots, p$, 均有 $f_i^1 \leq f_i^2$ 。


(3) " $\leq$ ": $F^1 \leq F^2$ 意味着向量 F^1 的每个分量都要小于或等于向量 F^2 对应的分量, 并且存在 F^1 的某一个分量要严格的小于向量 F^2 对应的分量。即对于 $i = 1, \dots, p$, 均有 $f_i^1 \leq f_i^2$, 并且要至少存在某个 $i_0 (1 \leq i_0 \leq p)$, 有 $f_{i_0}^1 < f_{i_0}^2$ 。

可见, " $F^1 \leq F^2$ " 等价于 " $F^1 \leq F^2$ " 且 " $F^1 \neq F^2$ "。



多目标规划模型及其解的概念

定义1 设 $X^* \in R$ ，若对任意 $X \in R$ ，均有 $F(X^*) \leq F(X)$ ，则称 X^* 为问题（VMP）的**绝对最优解**。其全体记为 R^*_{ab} 。



绝对最优解示意图

注：绝对最优解往往不存在！




多目标规划模型及其解的概念

定义2 设 $X^0 \in R$, 若存在另一个可行解 $X^1 \in R$, 有 $F(X^1) \leq F(X^0)$, 则称可行解 X^0 相对于 X^1 来说是**劣解**。

注: 决策中, 劣解不会被考虑!

定义3 设 $\bar{X} \in R$, 若不存在 $X \in R$, 使 $F(X) \leq F(\bar{X})$, 则称 $\bar{X}$ 为问题的**非劣解**, 又称**有效解**, 或**Pareto解**。其全体记为 R_{pa}^* 。






多目标规划模型及其解的概念

定义4 设 $\bar{X} \in R$, 若不存在 $X \in R$, 使 $F(X) < F(\bar{X})$, 则称 $\bar{X}$ 为问题的**弱有效解**。其全体记为 R_{wp}^* 。

注：有效解必是弱有效解。





多目标规划模型及其解的概念

	数学	外语	专业	解的类型
d_1	80	75	88	有效解
d_2	75	81	85	有效解
d_3	76	78	89	有效解
d_4	78	74	86	劣解
d_5	80	75	86	弱有效解

提问： 80 74 86 是弱有效解吗？




多目标规划模型及其解的概念

多目标规划—解的关系

定理1 $R_{ab}^* = \bigcap_{i=1}^p R_i^*$, 其中 R_i^* 为单目标 $f_i(X)$ 上最优点集合。

定理2 $R_{ab}^* \subseteq R_{pa}^* \subseteq R_{wp}^* \subset R$





多目标规划模型及其解的概念

多目标规划——解的关系

定理3 $R_i^* \subseteq R_{wp}^*$


定理4 若 $R_{ab}^* \neq \phi$, 则

$$(1) R_{pa}^* = R_{ab}^* = \bigcap_{i=1}^p R_i^*; \quad (2) R_{wp}^* = \bigcup_{i=1}^p R_i^*$$




多目标规划模型及其解的概念

多目标规划—解的关系



$$p=3 \quad R_{ab}^* = \varnothing$$



$$p=3 \quad R_{ab}^* \neq \varnothing$$



多目标规划

§ 1 多目标决策简介

§ 2 多目标规划模型及其解的概念

§ 3 多目标规划的解法



多目标规划的解法

- 求：有效解或弱有效解
- 方法分类
 - 评价函数法
 - 目标排序法
- 准备工作：目标函数规范化

$$f_i(X) = \frac{\bar{f}_i(X)}{\bar{f}_i}, \text{ 其中 } \bar{f}_i = \left| \max_{X \in R} \bar{f}_i(X) \right|$$



多目标规划的解法

一、评价函数法:

评价函数法就是利用一个复合函数:

$$h(F) = h(f_1, \dots, f_p)$$

把多目标问题(VMP)转化为单目标问题:

$$(P) \quad \min_{X \in R} h[F(X)]$$

然后来求解, 而单目标问题的解法我们是熟知的。问题是, 用评价函数 $h(F)$ 得到的(P)的最优解 $\bar{X}$ 是否为原问题(VMP)的有效解或弱有效解? 因为若连弱有效解都不是, 那显然是不足取的。



多目标规划的解法

下面我们将指出，当评价函数 $h(F)$ 具有某种“单调性时”，是可以保证 $\bar{X} \in R_{pa}^*$ （或 $\bar{X} \in R_{wp}^*$ ）的。为此，先给出两个定义：

定义4 设 $h(F)$ 是定义在 E_p 上的函数，若对于任意满足 $F^1 \leq F^2$ 的 $F^1 \in E_p$, $F^2 \in E_p$, 均有：

$$h(F^1) < h(F^2)$$

则称 $h(F)$ 为严格单调函数。

定义5 设 $h(F)$ 是定义在 E_p 上的函数，若对于任意满足 $F^1 < F^2$ 的 $F^1 \in E_p$, $F^2 \in E_p$, 均有：

$$h(F^1) < h(F^2)$$

则称 $h(F)$ 为单调函数。



多目标规划的解法

定理6 若 $h(F)$ 为定义在 E_p 上的严格单调函数, $\bar{X}$ 为规划问题

$$(p) \min_{X \in R} h[F(X)]$$

的最优解, 则 $\bar{X} \in R_{pa}^*$ 。

证: 用反证法。若 $\bar{X} \notin R_{pa}^*$, 则存在 $Y \in R$, 有 $F(Y) \leq F(\bar{X})$, 由 $h(F)$ 的严格单调性, 有

$$h[F(Y)] < h[F(\bar{X})]$$

这与 $\bar{X}$ 为问题 (p) 的最优解矛盾, 故 $\bar{X} \in R_{pa}^*$ 。

定理7 若 $h(F)$ 为定义在 E_p 上的单调函数, $\bar{X}$ 为规划问题

$$(p) \min_{X \in R} h[F(X)]$$

的最优解, 则 $\bar{X} \in R_{wp}^*$ 。

证明方法与定理6雷同。



多目标规划的解法

一、评价函数法

1. 线性加权和法

2. 理想点法

3. 目标规划法

二、目标排序法



多目标规划的解法

1、线性加权和法

该方法就是取评价函数为各目标函数的线性加权和，
即

$$h(F) = \lambda_1 f_1 + \dots + \lambda_p f_p$$

其中 $\lambda_1, \dots, \lambda_p$ 为相应目标的权系数。

线性加权和法的步骤如下：

(1) 依目标的重要程度给出一组权系数 $\lambda_1, \dots, \lambda_p$,

其中 $\lambda_i \geq 0, i = 1, \dots, p, \sum_{i=1}^p \lambda_i = 1$ 。



多目标规划的解法

(2)将(VMP)转化为单目标问题

$$(P_\lambda) \quad \min_{X \in R} \sum_{i=1}^p \lambda_i f_i(X)$$

求解 (P_λ) 得最优解 $\bar{X}$ 。

(3)可以证明, $\bar{X}$ 是(VMP)的弱有效解, 即 $\bar{X} \in R_{wp}^*$ 。进一步, 若所有权系数均为正, 即 $\lambda_i > 0, i = 1, \dots, p$, 则 $\bar{X} \in R_{pa}^*$ 。



多目标规划的解法

- 确定权系数常用方法： α -法
- α -法的步骤（以两个目标为例）：

$$U[F(X)] = \alpha_1 f_1(X) + \alpha_2 f_2(X)$$

(1) 求解单目标优化问题

(问题一) $\min_{X \in R} f_1(X) = f_1(X^1)$, 记

$$f_1^1 = f_1(X^1), f_2^1 = f_2(X^1)$$

(问题二) $\min_{X \in R} f_2(X) = f_2(X^2)$, 记

$$f_2^2 = f_2(X^2), f_1^2 = f_1(X^2)$$



多目标规划的解法

(2) α -方法的出发点: $U[F(X^1)] = U[F(X^2)]$

$$\begin{cases} \alpha_1 f_1^1 + \alpha_2 f_2^1 = \alpha_1 f_1^2 + \alpha_2 f_2^2 \\ \alpha_1 + \alpha_2 = 1 \end{cases}$$

$$\alpha_1 = \frac{f_2^2 - f_2^1}{f_2^2 - f_2^1 + f_1^1 - f_1^2}; \quad \alpha_2 = \frac{f_1^1 - f_1^2}{f_2^2 - f_2^1 + f_1^1 - f_1^2}$$


(3) 求解 $\min_{X \in R} U[F(X)] = \min_{X \in R} [\alpha_1 f_1(X) + \alpha_2 f_2(X)]$

得 X^*



多目标规划的解法

α -方法的几何意义:

$$X^1 \rightarrow (f_1^1, f_2^1): A \text{ 点}; \quad X^2 \rightarrow (f_1^2, f_2^2): B \text{ 点}$$


(1) 平行直线簇 $a_1f_1 + a_2f_2 = c$;

(2) 同一条直线上 X^1 与 X^2 有相同的评价值, 即有

$$U \left[F(X^1) \right] = U \left[F(X^2) \right] \text{。}$$



矩阵计算与优化 (最优化--多目标与随机优化)

例 设 $f_1(X) = 4x_1 + x_2 \rightarrow \min, f_2(X) = -3x_1 - 2x_2 \rightarrow \min$

有 $R = \{X \mid 2x_1 + x_2 \leq 4, x_1 + x_2 \leq 3, x_1, x_2 \geq 0, X \in R^2\}$

试用 α -法求解。

解： 求解单目标优化问题，得 $X^1 = (0,0)^T, X^2 = (1,2)^T$

$$f_1^1 = f_1(X^1) = 0, f_2^1 = f_2(X^1) = 0$$

$$f_1^2 = f_1(X^2) = 6, f_2^2 = f_2(X^2) = -7$$

$$\alpha_1 = \frac{f_2^2 - f_2^1}{f_2^2 - f_2^1 + f_1^1 - f_1^2} = \frac{7}{13}, \quad \alpha_2 = \frac{6}{13}$$

$$U(X) = \frac{7}{13} f_1(X) + \frac{6}{13} f_2(X) = \frac{10}{13} x_1 - \frac{5}{13} x_2$$

求解LP

$$\min_{X \in R} U(X) = U(0,3) = -\frac{15}{13}$$



多目标规划的解法

一、评价函数法

1. 线性加权和法（ α -法确定权系数）

2. 理想点法

3. 目标规划法

二、目标排序法




2. 理想点法

基本思想： X 的评价向量 $F(X) = (f_1(X), f_2(X), \dots, f_p(X))$ 越接近理想点越好。

理想点： 一般指由各单目标最优值组成的 p 维点

$$F^* = (f_1^*, \dots, f_p^*)$$





理想点法的步骤:

(1) 求理想点。求解 p 个单目标最优化问题

$$\min_{X \in R} f_i(X) = f_i(X^i) = f_i^* \quad i = 1, 2, \dots, p$$

得理想点: $F^* = (f_1^*, \dots, f_p^*)$

(2) 检验理想点。绝对最优点, 则输出绝对最优解,

$X^* = X^i$, 求解完毕。否则, 转(3)。



理想点法的步骤:

(3) 作评价函数。

$$U[F(X)] = \|F(X) - F^*\| = \left[\sum_{i=1}^p (f_i(X) - f_i^*)^q \right]^{\frac{1}{q}}$$

(4) 求解 $\min_{X \in R} U[F(X)] \rightarrow \bar{X}$

Note: 距离函数是天然严格增函数，故按其求得的解是(VMP)的有效解。



例： 设 $f_1(X)=-3x_1+2x_2$, $f_2(X)=4x_1+3x_2$ 都要求实现最大, 约束集为 $R = \{X|2x_1+3x_2 \leq 18, 2x_1+x_2 \leq 10, x_1, x_2 \geq 0, X \in R^2\}$, 试用理想点法求解。

解： 先分别求解两个单目标问题 $\max_{X \in R^2} f_i(X) \quad i=1,2$

$$X^{(1)}=(0,6), f_1^*=12; \quad X^{(2)}=(3,4), \quad f_2^*=24$$

$$\text{理想点 } F^*=(f_1^*, f_2^*)=(12,24)$$

$$\text{评价函数 } \min_{X \in R} [(f_1(X) - f_1^*)^2 + (f_2(X) - f_2^*)^2]^{\frac{1}{2}}$$

$$X^*=(0.53,5.65), \quad f_1^*=9.72, f_2^*=19.06。$$



§ 3 多目标规划的解法

一、评价函数法

1. 线性加权和法（ α -法确定权系数）
2. 理想点法
3. 目标规划法

二、目标排序法



3 目标规划法 (Goal Programming)

(一) 目标规划的思想

是求解多目标规划的一种常用方法。

该方法不考虑对各个目标进行极小化或极大化，而是希望在约束条件的限制下，每一目标尽可能地接近于事先给定的目的值。



矩阵计算与优化（最优化--多目标与随机优化）

例：某工厂生产**I**、**II**两种产品，有关数据如下表：

	I	II	资源量
原材料	2	1	11
设备	1	2	10
利润	8	10	

决策者在原材料供应受严格限制的基础上，考虑尽量满足如下条件：

- (1)** 首先，产品**II**的产量高于产品**I** 的产量；
- (2)** 其次，充分利用设备有效台时，不加班；
- (3)** 再次，利润额不小于**56**元。



(二) 目标规划的数学模型


分析:

(1) 在每个目标 $f_i(X)$ 上预先确定一个希望达到的目标值, 得一目标值向量

$$F = (f_1^0, f_2^0, \dots, f_p^0)$$

(2) 构造评价函数

$$\sum_{i=1}^p |f_i(X) - f_i^0|$$

(3) 多目标决策问题  单目标问题

$$\min_{x \in R} \sum_{i=1}^p |f_i(X) - f_i^0|$$

(其中 R 为问题的可行域)



$$\min_{x \in R} \sum_{i=1}^p |f_i(X) - f_i^0|$$

(4) 为了求解(3)，引入类偏差变量

正偏差 $d_i^+ = \begin{cases} f_i(X) - f_i^0, & f_i(X) > f_i^0 \\ 0 & f_i(X) \leq f_i^0 \end{cases} \quad i = 1, 2, \dots, p$

负偏差 $d_i^- = \begin{cases} 0 & f_i(X) \geq f_i^0 \\ f_i^0 - f_i(X) & f_i(X) < f_i^0 \end{cases}, \quad i = 1, 2, \dots, p$

可以证明 (3) 等价于

$$\min \sum_{i=1}^p (d_i^+ + d_i^-)$$

$$\begin{cases} f_i(X) - d_i^+ + d_i^- = f_i^0 \\ X \in R \\ d_i^+ \geq 0, d_i^- \geq 0 \end{cases} \quad i = 1, 2, \dots, p$$

目标约束
(软约束)

绝对约束
(硬约束)



实际问题中：

- ①各目标可赋予不同的优先因子 P_j ；
- ②相同优先因子的两个目标的差别，可分别赋予它们不同的权系数 ω_{ij}

于是得到目标规划模型：

$$\begin{aligned} \min & \sum_{j=1}^l P_j \left(\sum_{i=1}^p \omega_{ji}^- d_i^- + \sum_{i=1}^p \omega_{ji}^+ d_i^+ \right) \\ & \begin{cases} f_i(X) - d_i^+ + d_i^- = f_i^0 \\ X \in R \\ d_i^+ \geq 0, d_i^- \geq 0 \quad (i=1, 2, \dots, p) \end{cases} \end{aligned}$$



$$\begin{aligned} \min & \sum_{j=1}^l P_j \left(\sum_{i=1}^p \omega_{ji}^- d_i^- + \sum_{i=1}^p \omega_{ji}^+ d_i^+ \right) \\ & \begin{cases} f_i(X) - d_i^+ + d_i^- = f_i^0 \\ X \in R \\ d_i^+ \geq 0, d_i^- \geq 0 \quad (i = 1, 2, \dots, p) \end{cases} \end{aligned}$$

目标规划模型的特点：

- （1）目标函数都是最小化，只有偏差变量和优先因子（不含一般决策变量）；
- （2）约束条件中既可包含目标约束，还可包含绝对约束；
- （3）目标约束均为等式；且一般在一个约束中同时含有正、负偏差变量；



另外，根据决策者的不同要求，目标函数有三种基本形式：

(1) 要求恰好达到目标值，评价函数为

$$\min \sum_{i=1}^p (d_i^+ + d_i^-)$$

(2) 要求超过目标值，评价函数为

$$\min \sum_{i=1}^p d_i^-$$

(3) 要求不超过目标值，评价函数为

$$\min \sum_{i=1}^p d_i^+$$



(三) 目标规划建模举例

例1: 某工厂生产**I**、**II**两种产品，有关数据如下表：

	I	II	资源量
原材料	2	1	11
设备	1	2	10
利润	8	10	

决策者在原材料供应受严格限制的基础上，考虑尽量满足如下条件：

- (1) 首先，产品**II**的产量高于产品**I** 的产量；
- (2) 其次，充分利用设备有效台时，不加班；
- (3) 再次，利润额不小于**56**元。



例1：某工厂生产**I**、**II**两种产品，有关数据如下表：

	I	II	资源量
原材料	2	1	11
设备	1	2	10
利润	8	10	

决策者在原材料供应受**严格限制**的基础上考虑：

- (1) 首先，产品**II**的产量高于产品**I** 的产量；
- (2) 其次，充分利用设备有效台时，不加班；
- (3) 再次，利润额不小于**56**元。

$$\begin{cases} \min [P_1 d_1^+ + P_2 (d_2^- + d_2^+) + P_3 d_3^-] \\ 2x_1 + x_2 \leq 11 \\ x_1 - x_2 + d_1^- - d_1^+ = 0 \\ x_1 + 2x_2 + d_2^- - d_2^+ = 10 \\ 8x_1 + 10x_2 + d_3^- - d_3^+ = 56 \\ x_1, x_2, d_i^+, d_i^- \geq 0 \quad (i=1, 2, 3) \end{cases}$$



(四) 目标规划的求解

(1) 图解法

先考虑绝对约束；再考虑目标约束，并令目标约束中的偏差变量为0，作直线。

Step1 P1 $\rightarrow \triangle OBC$


Step2 P2 $\rightarrow$ 线段ED

Step3 P3 $\rightarrow$ 目标规划的解：线段GD. 其中，
G(2,4), D(10/3,10/3)

注：该例求得最优解，且 $Z^*=0$. 但大多问题可能无法满足所有约束，此时求满意解。

$$\min [P_1 d_1^+ + P_2 (d_2^- + d_2^+) + P_3 d_3^-]$$

$$\begin{cases} 2x_1 + x_2 \leq 11 \\ x_1 - x_2 + d_1^- - d_1^+ = 0 \quad ① \\ x_1 + 2x_2 + d_2^- - d_2^+ = 10 \quad ② \\ 8x_1 + 10x_2 + d_3^- - d_3^+ = 56 \quad ③ \\ x_1, x_2, d_i^+, d_i^- \geq 0 \quad (i=1, 2, 3) \end{cases}$$





多目标规划的解法

一、评价函数法

1. 线性加权和法（ α -法确定权系数）
2. 理想点法
3. 目标规划法

二、目标排序法



多目标规划的解法

二、目标排序法（简介）


➤ **思想：** 把目标按其重要性排序，设给出的重要性序列为 $f_1(X), f_2(X), \dots, f_p(X)$ ，然后按这种排序逐步进行一系列单目标优化，最后求出满意解。

➤ **方法**  **序列最优化法**
宽容意义下的序列优化方法




1. 序列最优化法

$$\min_{X \in R} f_1(X) = f_1^*(X_1)$$



最优解集 R_1


$$\min_{X \in R_1 \subseteq R} f_2(X) = f_2^*(X_2)$$



最优解集 R_2


...

$$\min_{X \in R_{p-2} \subseteq R_{p-3}} f_{p-1}(X) = f_{p-1}^*(X_{p-1})$$



最优解集 R_{p-1}

$$\min_{X \in R_{p-1} \subseteq R_{p-2}} f_p(X) = f_p^*(X_p)$$



最优解 X_p

缺点： 由于某一步最优解唯一时，以后的目标的优化就不能进行下去了。



2. 宽容意义下的序列优化方法

预先给定 $\varepsilon_1 > 0, \varepsilon_2 > 0, \dots, \varepsilon_{p-1} > 0$ 作为宽容值

$$\min_{X \in R} f_1(X) = f_1^*(X_1)$$

$$\min_{X \in R_1} f_2(X) = f_2^*, R_1 = \{X | f_1(X) < f_1^* + \varepsilon_1, X \in R\}$$

⋮

$$\min_{X \in R_{p-1}} f_p(X) = f_p^*(X_p), R_{p-1} = \{X | f_{p-1}(X) < f_{p-1}^* + \varepsilon_{p-1}, X \in R_{p-2}\}$$

则 X_p 为多目标问题的最优解。



大纲

- 多目标优化
- 随机优化



优化算法**智能化**的初步递进

- **梯度下降 → 随机梯度下降**



梯度下降 → 随机梯度下降

随机梯度下降（通常缩写为SGD）是一种迭代方法，用于优化具有适当平滑性质（例如可微分或次可微分）的目标函数。它可以被视为**梯度下降优化的随机近似**，因为它用实际梯度（根据整个数据集计算）的估计值（根据**随机选择的数据子集计算**）代替了实际梯度。尤其是在高维优化问题中，这可以减轻非常高的计算负担，并以**较低的收敛速度实现更快的迭代速度**。



SGD的重要历史

- 1951 年，Herbert Robbins和Sutton Monro提出最早的随机近似方法
- 1952 年，Jack Kiefer和Jacob Wolfowitz发表了一种非常接近随机梯度下降的优化算法，使用中心差分作为梯度的近似值。
- 1957-1958 年，Frank Rosenblatt用 SGD 训练感知机模型，首次用于神经网络。
- 1986年，Hinton等人提出反向传播算法，确立了SGD在多层网络训练中的核心地位。
- 1997年，小批量梯度下降法开始流行，为机器学习中的高效优化铺平了道路。截至目前，这种小批量方法仍然是神经网络训练的标准，它平衡了随机梯度下降法和梯度下降法的优势。



SGD的重要历史

- **1986年**，动量（Momentum）被添加到SGD优化技术中，帮助加速收敛并减少震荡。
- **2011年**，**AdaGrad（"自适应梯度"）**发布，应用每个参数都指定学习率的SGD自适应方法，能够自动调整学习率。
- **2012年**，**RMSprop（"均方根传播"）**发布，改进了AdaGrad学习率单调递减的问题。
- **2014年**，**Adam（"自适应矩估计"）**发布，将RMSprop的自适应方法应用于动量，结合了动量和自适应学习率的优点；随后，Adam的许多改进和分支被开发出来，例如Adadelta、AdamW和Adamax。
- **截至目前**，TensorFlow和PyTorch是迄今为止最受欢迎的机器学习库，它们基本上只包含Adam衍生的优化器，以及Adam的前身，例如RMSprop和经典的SGD。



梯度下降 → 随机梯度下降

待求解问题（目标函数）：

$$Q(w) = \frac{1}{n} \sum_{i=1}^n Q_i(w),$$

传统标准梯度下降（GD）：

$$w := w - \eta \nabla Q(w) = w - \frac{\eta}{n} \sum_{i=1}^n \nabla Q_i(w).$$


随机梯度下降（SGD）：

$$w := w - \eta \nabla Q_i(w).$$



梯度下降 → 随机梯度下降

- 选择参数的初始向量 w 和学习率 η 。
- 重复直到获得近似最小值：
 - 随机打乱训练集中的样本。
 - 为了 $i = 1, 2, \dots, n$ ，做：
 - $w := w - \eta \nabla Q_i(w)$.



注意：再小的步长也不一定能带来目标函数的严格下降！



梯度下降 → 随机梯度下降

问题设定

- **任务**：二分类问题，预测患病概率。
- **模型**：逻辑回归（含偏置项）： $\hat{y} = \sigma(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$ ，
其中 $\sigma(z) = \frac{1}{1+e^{-z}}$ 是 Sigmoid 函数。
- **损失函数**：交叉熵 + L2 正则化： $L = -\frac{1}{m} \sum_{i=1}^m [y_i \ln \hat{y}_i + (1 - y_i) \ln(1 - \hat{y}_i)] + \frac{\lambda}{2}(\theta_1^2 + \theta_2^2)$ 。
- **数据集**：3 个样本，每个样本 2 个特征： $X = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 2 & 1 \end{bmatrix}$, $y = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$ 。
- **参数**：初始 $\theta_0 = 0, \theta_1 = 0, \theta_2 = 0$ ，学习率 $\eta = 0.01$ ，正则化系数 $\lambda = 0.1$ 。



梯度下降（具体计算）

第一步：Sigmoid函数的导数

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

求导：

$$\sigma'(z) = \frac{e^{-z}}{(1+e^{-z})^2} = \frac{1}{1+e^{-z}} \cdot \frac{e^{-z}}{1+e^{-z}} = \sigma(z) \cdot (1 - \sigma(z))$$

即：

$$\sigma'(z) = \hat{y}(1 - \hat{y})$$



梯度下降（具体计算）

第二步：对 θ_0 的梯度推导

链式法则路径：

$$\theta_0 \rightarrow z \rightarrow \hat{y} \rightarrow L$$

$$\frac{\partial L}{\partial \theta_0} = \frac{\partial L}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z} \cdot \frac{\partial z}{\partial \theta_0}$$

逐层计算：

1. $\frac{\partial z}{\partial \theta_0} = 1$

2. $\frac{\partial \hat{y}}{\partial z} = \hat{y}(1 - \hat{y})$ (Sigmoid导数)

3. $\frac{\partial L}{\partial \hat{y}}$ (只看交叉熵部分，忽略正则化，因为 θ_0 没有正则化项)

对单个样本：

$$L_i = -[y_i \ln \hat{y}_i + (1 - y_i) \ln(1 - \hat{y}_i)]$$

$$\begin{aligned} \frac{\partial L_i}{\partial \hat{y}_i} &= - \left[\frac{y_i}{\hat{y}_i} - \frac{1-y_i}{1-\hat{y}_i} \right] = - \frac{y_i(1-\hat{y}_i) - (1-y_i)\hat{y}_i}{\hat{y}_i(1-\hat{y}_i)} \\ &= - \frac{y_i - y_i\hat{y}_i - \hat{y}_i + y_i\hat{y}_i}{\hat{y}_i(1-\hat{y}_i)} = - \frac{y_i - \hat{y}_i}{\hat{y}_i(1-\hat{y}_i)} = \frac{\hat{y}_i - y_i}{\hat{y}_i(1-\hat{y}_i)} \end{aligned}$$

三层相乘：

$$\frac{\partial L_i}{\partial \theta_0} = \frac{\hat{y}_i - y_i}{\hat{y}_i(1-\hat{y}_i)} \cdot \hat{y}_i(1 - \hat{y}_i) \cdot 1 = \hat{y}_i - y_i$$

对所有样本平均：

$$\frac{\partial L}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)$$



梯度下降（具体计算）

梯度推导（关键公式）

对 θ_0 的梯度: $\frac{\partial L}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)$

对 θ_j ($j = 1, 2$) 的梯度: $\frac{\partial L}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i) x_{i,j} + \lambda \theta_j$



矩阵计算与优化（最优化--多目标与随机优化）

第1次迭代

1. 计算所有样本的预测值:

- 样本 1: $z_1 = 0 + 0 \times 1 + 0 \times 2 = 0, \hat{y}_1 = \sigma(0) = 0.5$
- 样本 2: $z_2 = 0 + 0 \times 3 + 0 \times 4 = 0, \hat{y}_2 = 0.5$
- 样本 3: $z_3 = 0 + 0 \times 2 + 0 \times 1 = 0, \hat{y}_3 = 0.5$

2. 计算梯度:

- $\frac{\partial L}{\partial \theta_0} = \frac{1}{3} [(0.5 - 1) + (0.5 - 0) + (0.5 - 1)] = \frac{1}{3} (-0.5 + 0.5 - 0.5) = -\frac{0.5}{3} \approx -0.1667$
- $\frac{\partial L}{\partial \theta_1} = \frac{1}{3} [(0.5 - 1) \times 1 + (0.5 - 0) \times 3 + (0.5 - 1) \times 2] + 0.1 \times 0 = \frac{1}{3} (-1 + 1.5 - 1) = -\frac{0.5}{3} \approx -0.1667$
- $\frac{\partial L}{\partial \theta_2} = \frac{1}{3} [(0.5 - 1) \times 2 + (0.5 - 0) \times 4 + (0.5 - 1) \times 1] + 0.1 \times 0 = \frac{1}{3} (-1 + 2 - 0.5) = \frac{0.5}{3} \approx 0.1667$

$$\theta_0 = 0 - 0.01 \times (-0.1667) \approx 0.0017,$$

3. 参数更新: $\theta_1 = 0 - 0.01 \times (-0.1667) \approx 0.0017,$

$$\theta_2 = 0 - 0.01 \times (0.1667) \approx -0.0017.$$



梯度下降（具体计算）

第 n 次迭代（理论趋势）

- **梯度稳定性**：每次梯度是所有样本的精确平均，方向稳定，无随机噪声。
- **收敛性**：若学习率合适（此处 $\eta = 0.01$ 较小），参数会单调收敛至最优解，无 SGD 的震荡现象。
- **计算量**：每次迭代需计算所有样本的梯度，时间复杂度为 $O(m)$ ，本例中 $m = 3$ 可忽略，但大数据集下计算成本高。



同问题，使用随机梯度下降

问题设定

- **任务：**二分类问题，预测患病概率。
- **模型：**逻辑回归（含偏置项）： $\hat{y} = \sigma(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$ ，
其中 $\sigma(z) = \frac{1}{1+e^{-z}}$ 是 Sigmoid 函数。
- **损失函数：**交叉熵 + L2 正则化： $L = -\frac{1}{m} \sum_{i=1}^m [y_i \ln \hat{y}_i + (1 - y_i) \ln(1 - \hat{y}_i)] + \frac{\lambda}{2}(\theta_1^2 + \theta_2^2)$ 。
- **数据集：**3 个样本，每个样本 2 个特征： $X = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 2 & 1 \end{bmatrix}$, $y = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$ 。
- **参数：**初始 $\theta_0 = 0, \theta_1 = 0, \theta_2 = 0$ ，学习率 $\eta = 0.01$ ，正则化系数 $\lambda = 0.1$ 。



随机梯度下降（具体计算）

第1次迭代：样本1 ($x_1 = 1, x_2 = 2, y = 1$)

1. 预测值：

$$z = 0 + 0 \cdot 1 + 0 \cdot 2 = 0$$

$$\hat{y} = \sigma(0) = 0.5$$

2. 梯度计算：

$$\frac{\partial L}{\partial \theta_0} = 0.5 - 1 = -0.5$$

$$\frac{\partial L}{\partial \theta_1} = (-0.5) \cdot 1 + 0.1 \cdot 0 = -0.5$$

$$\frac{\partial L}{\partial \theta_2} = (-0.5) \cdot 2 + 0 = -1.0$$

3. 参数更新：

$$\theta_0 = 0 - 0.01 \times (-0.5) = 0.005$$

$$\theta_1 = 0 - 0.01 \times (-0.5) = 0.005$$

$$\theta_2 = 0 - 0.01 \times (-1.0) = 0.010$$



随机梯度下降（具体计算）

第2次迭代：样本3 ($x_1 = 2, x_2 = 1, y = 1$)

1. 预测值：

$$z = 0.005 + 0.005 \cdot 2 + 0.010 \cdot 1 = 0.005 + 0.010 + 0.010 = 0.025$$

$$\hat{y} = \sigma(0.025) \approx 0.5062$$

2. 梯度计算：

$$\frac{\partial L}{\partial \theta_0} = 0.5062 - 1 = -0.4938$$

$$\frac{\partial L}{\partial \theta_1} = (-0.4938) \cdot 2 + 0.1 \cdot 0.005 = -0.9876 + 0.0005 = -0.9871$$

$$\frac{\partial L}{\partial \theta_2} = (-0.4938) \cdot 1 + 0.1 \cdot 0.010 = -0.4938 + 0.001 = -0.4928$$

3. 参数更新：

$$\theta_0 = 0.005 - 0.01 \times (-0.4938) = 0.0099$$

$$\theta_1 = 0.005 - 0.01 \times (-0.9871) = 0.0149$$

$$\theta_2 = 0.010 - 0.01 \times (-0.4928) = 0.0149$$



随机梯度下降（具体计算）

第3次迭代：样本2 ($x_1 = 3, x_2 = 4, y = 0$)

1. 预测值：

$$z = 0.0099 + 0.0149 \cdot 3 + 0.0149 \cdot 4 = 0.0099 + 0.0447 + 0.0596 = 0.1142$$

$$\hat{y} = \sigma(0.1142) \approx 0.5285$$

2. 梯度计算：

$$\frac{\partial L}{\partial \theta_0} = 0.5285 - 0 = 0.5285$$

$$\frac{\partial L}{\partial \theta_1} = 0.5285 \cdot 3 + 0.1 \cdot 0.0149 = 1.5855 + 0.0015 = 1.5870$$

$$\frac{\partial L}{\partial \theta_2} = 0.5285 \cdot 4 + 0.1 \cdot 0.0149 = 2.1140 + 0.0015 = 2.1155$$

3. 参数更新：

$$\theta_0 = 0.0099 - 0.01 \times 0.5285 = 0.0046$$

$$\theta_1 = 0.0149 - 0.01 \times 1.5870 = -0.0010$$

$$\theta_2 = 0.0149 - 0.01 \times 2.1155 = -0.0063$$



梯度下降 → 随机梯度下降

特性	梯度下降 (GD)	随机梯度下降 (SGD)
梯度计算	所有样本的平均梯度	单个样本的梯度
参数更新方向	稳定（基于全局平均信息）	随机（基于单个样本噪声）
迭代路径	平滑，无震荡	波动大，可能出现震荡
收敛速度	初期可能较慢（需计算全梯度），后期稳定收敛	初期快（单个样本更新灵活），后期因噪声收敛变慢
适用场景	小数据集或内存可容纳全数据	大规模数据集（每次计算量小）
正则化影响	梯度含全局平均正则化项	梯度含单个样本正则化项（噪声更大）



第6次实验课分组展示内容：

- 围绕深度学习各类优化算法（SGD、Adam等）开展理论分析，在大规模样本数据集上完成模型训练（分类、分割、图像生成等）；统一明确配置批大小、随机种子、学习率与优化器、损失函数等关键超参，对比 SGD、Adam 等主流优化算法的损失收敛趋势与模型精度表现，并据此展开实验分析。
- 注：请大家讲清任务设置，并专注在不同优化器的理论、实验分析上



第6次实验课分组展示内容：

- （仅参考，可自选）相关的Github链接为：
 - <https://github.com/WZMIAOMIAO/deep-learning-for-image-processing>
 - <https://github.com/milesial/pytorch-unet>
 - <https://github.com/eriklindernoren/PyTorch-GAN>
- 实验课按小组开展，后续开放现场汇报报名表填报，10号下午2点发布。仅想要上台汇报的小组提交，按提交顺序选择（并综合考虑大家的选题和之前作业情况）。



感谢聆听!