

矩阵计算与优化

Matrix Computation and Optimization

吕月明

南京大学智能科学与技术学院



第五章 线性方程组的解

线性方程组的数值解法（直接法）

Gauss 消元法

设 $A = (a_{ij}) \in \mathbf{C}^{n \times n}$, $b = (b_1, b_2, \dots, b_n)^T \in \mathbf{C}^n$, 求解线性方程组

$$Ax = b.$$

如果 A 是一个下三角矩阵, 即对于 $j > i$, $a_{ij} = 0$, 而且 $a_{ii} \neq 0, i = 1, 2, \dots, n$, 我们可以从第一个方程求得 x_1 , 代入第二个方程求得 x_2 , 这样逐次向前代入求出 x 的所有分量.

如果 A 是一个上三角矩阵, 即对于 $i > j$, $a_{ij} = 0$, 而且 $a_{ii} \neq 0, i = 1, 2, \dots, n$, 我们可以从最后一个方程求得 x_n , 代入第 $n-1$ 个方程求得 x_{n-1} , 这样逐次向后回代求出 x 的所有分量.

基本思想

Gauss 消元法的基本思想是：将系数矩阵 A 逐次消去成上三角矩阵，再逐次向后回代求出方程组的解。

消元过程: 第 1 步

从第 2 个方程到第 n 个方程消去未知量 x_1 , 设 $a_{11} \neq 0$, 令 $l_{i1} = -\frac{a_{i1}}{a_{11}}$, 计算

$$\begin{cases} a_{i1} := 0; \\ a_{ij} := a_{ij} + l_{i1}a_{1j}; \\ b_i := b_i + l_{i1}b_1, \quad i, j = 2, 3, \dots, n. \end{cases}$$

这一步的运算等价于用初等矩阵

$$L_1 = \begin{pmatrix} 1 & & & \\ l_{21} & 1 & & \\ \vdots & & \ddots & \\ l_{n1} & 0 & \cdots & 1 \end{pmatrix}$$

左乘方程组两端: $L_1 A x = L_1 b$.

消元过程: 第 2 步

设方程组 $L_1Ax = L_1b$ 中 $a_{22} \neq 0$, 从第 3 个方程到第 n 个方程消去未知量 x_2 ,

$$\begin{cases} l_{i2} &:= -\frac{a_{i2}}{a_{22}}; \\ a_{i2} &:= 0; \\ a_{ij} &:= a_{ij} + l_{i2}a_{2j}; \\ b_i &:= b_i + l_{i2}b_2, \quad i, j = 3, 4, \dots, n. \end{cases}$$

这一步的运算等价于用初等矩阵

$$L_2 = \begin{pmatrix} 1 & & & & 0 \\ 0 & 1 & & & \\ 0 & l_{32} & 1 & & \\ \vdots & & & \ddots & \\ 0 & l_{n2} & 0 & \cdots & 1 \end{pmatrix}$$

左乘方程组两端: $L_2L_1Ax = L_2L_1b$.

上三角化与回代

在完成 $n-1$ 步后, 原方程组就化为与其等价的上三角形方程组

$$\left. \begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1 \\ a_{22}x_2 + \cdots + a_{2n}x_n &= b_2 \\ &\vdots \\ a_{nn}x_n &= b_n \end{aligned} \right\}$$

利用逐次回代把 $x_n, x_{n-1}, \cdots, x_1$ 计算出来

$$\begin{cases} x_n = \frac{b_n}{a_{nn}} \\ x_k = \frac{1}{a_{kk}} \left(b_k - \sum_{j=k+1}^n a_{kj}x_j \right), \\ k = n-1, n-2, \cdots, 1 \end{cases}$$

Gauss 消元法总结

总之, Gauss 消元法分两大过程进行:

1. 消元过程: 经过 $n-1$ 步消元将原方程组化成等价的上三角形方程组

$$A^{(n)}x = b^{(n)}.$$

其算法可描述为: 对 $k = 1, 2, \dots, n-1$, 设 $a_{kk}^{(k)} \neq 0$, 对 $i = k+1, \dots, n$ 计算

$$\begin{cases} l_{ik} = -a_{ik}^{(k)} / a_{kk}^{(k)}; \\ a_{ij}^{(k+1)} = a_{ij}^{(k)} + l_{ik} a_{kj}^{(k)}; \\ b_i^{(k+1)} = b_i^{(k)} + l_{ik} b_k^{(k)}, j = k+1, \dots, n. \end{cases}$$

Gauss 消元法总结 (续)

2. 回代过程: 利用逐步回代, 求解三角形方程组. 算法可描述为:

$$\begin{cases} x_n = b_n^{(n)} / a_{nn}^{(n)}; \\ x_k = \left(b_k^{(n)} - \sum_{j=k+1}^n a_{kj}^{(k)} x_j \right) / a_{kk}^{(k)}, \\ k = n-1, n-2, \dots, 1. \end{cases}$$

从上面消元法过程可以看出, Gauss 消元步骤能够顺序进行的条件是主元素 $a_{11}^{(1)}, a_{22}^{(2)}, \dots, a_{n-1,n-1}^{(n-1)}$ 全不为 0, 回代步骤还要求 $a_{nn}^{(n)} \neq 0$.

定理

(i) $a_{ii}^{(i)} (i = 1, 2, \dots, k)$ 全不为 0 的充要条件是 A 的顺序主子式 $\Delta_i \neq 0, i = 1, 2, \dots, k$, 其中 $k \leq n$.

(ii) 若 A 的顺序主子式均不为零, 则可用 Gauss 消元法求出方程组 $Ax = b$ 的解.

舍入误差分析

Gauss 消元法中每步要用到主元素 a_{ij} 作除数, 当主元素绝对值很小时, 可能引起很大的舍入误差.

例: 用 3 位十进制浮点运算求解

$$\begin{cases} 1.00 \times 10^{-5}x_1 + 1.00x_2 = 1.00 \\ 1.00x_1 + 1.00x_2 = 2.00. \end{cases}$$

误差分析 (续)

解: 方程组的准确解显然接近 $(1.00, 1.00)^T$, 但是系数 $a_{11} = 1.00 \times 10^{-5}$ 与其它系数比较是个较小的数.

如果我们用顺序 Gauss 消元法求解, 则有

$$l_{21} = \frac{a_{21}}{a_{11}} = 1.00 \times 10^5$$

$$a_{22}^{(2)} = a_{22} - l_{21} a_{12} = 1.00 - 1.00 \times 10^5$$

$$b_2^{(2)} = b_2 - l_{21} b_1 = 2.00 - 1.00 \times 10^5$$

在 3 位十进制运算的限制下, 得到

$$x_2 = b_2^{(2)} / a_{22}^{(2)} = 1.00,$$

回代得 $x_1 = 0.00$, 显然这是不正确的解.

原因与改进

因为用较小的数 a_{11} 做除数, 使 l_{21} 是个较大的数, 在计算 $a_{22}^{(2)}$ 的过程中 a_{22} 的值完全被掩盖了.

如果先交换方程组的两个方程的顺序, 再用 Gauss 消元法, 就不会出现上述问题, 解得

$$x_1 = 1.00, x_2 = 1.00.$$

列主元素法

为克服这个缺点, 可用部分主元素法 (或称列主元素法):

第 1 步: 在 x_1 的系数中, 即系数矩阵 A 的第一列中取按模最大者作为主元, 设

$$|a_{r1}| = \max_{1 \leq i \leq n} |a_{i1}|$$

交换第 1 个方程与第 r 个方程, 即把 a_{r1} 换在 a_{11} 的位置上, 再按 Gauss 消元法第 1 步消元.

列主元素法 (续)

第 k 步: 在第 k 到第 n 个方程中找出未知数 x_k 系数中按模最大者, 设

$$|a_{r_k k}| = \max_{k \leq j \leq n} |a_{jk}|$$

交换第 k 个方程与第 r_k 个方程, 即把 $a_{r_k k}$ 换在 a_{kk} 的位置上, 再按 Gauss 消元法第 k 步消元.

列主元素算法流程

部分主元素算法如下: 对于 $k = 1, 2, \dots, n$,

1. 找 $\rho_k \geq k$, 使得 $|a_{\rho_k k}| = \max \{|a_{ik}|, i \geq k\}$;
2. 如果 $a_{\rho_k k} = 0$, 停止计算, 否则转下一步;
3. $a_{kj} \leftrightarrow a_{\rho_k k}$, $j = k, k+1, \dots, n$, $b_k \leftrightarrow b_{\rho_k}$;
4. 计算 $l_{ik} = \frac{a_{ik}}{a_{kk}}$, $i = k+1, k+2, \dots, n$;
5. $a_{ij} = a_{ij} - l_{ik}a_{kj}$, $i, j = k+1, \dots, n$,
 $b_i = b_i - l_{ik}b_k$, $i = k+1, \dots, n$.

三角分解解法

将 A 分解成一个下三角矩阵 L 与一个上三角矩阵 U 的乘积

$$A = LU.$$

线性方程组 $Ax = b$ 的求解就变成了两个三角形方程组

$$\begin{cases} Ly = b \\ Ux = y \end{cases} \quad (1)$$

的求解问题.

Doolittle 方法

作 A 的 Doolittle 分解

$$A = LU$$

其中 $L = (l_{ij})$ 是单位下三角矩阵, $U = (u_{ij})$ 是上三角矩阵, 再求解 (1).

计算公式

计算公式是

$$y_i = b_i - \sum_{k=1}^{i-1} l_{ik} y_k \quad (2)$$
$$i = 1, 2, \dots, n,$$

$$x_i = \left(y_i - \sum_{k=i+1}^n U_{ik} x_k \right) / u_{ii}, \quad (3)$$
$$i = n, n-1, \dots, 1.$$

例题

用 Doolittle 方法求解

$$\begin{pmatrix} 6 & 2 & 1 & -1 \\ 2 & 4 & 1 & 0 \\ 1 & 1 & 4 & -1 \\ -1 & 0 & -1 & 3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 6 \\ -1 \\ 5 \\ -5 \end{pmatrix}.$$

例题求解 (分解)

解: 第 1 步, 对系数矩阵作 Doolittle 分解, 即 $A = LU$,

$$L = \begin{pmatrix} 1 & & & \\ \frac{1}{3} & 1 & & \\ \frac{1}{6} & \frac{1}{5} & 1 & \\ -\frac{1}{6} & \frac{1}{10} & -\frac{9}{37} & 1 \end{pmatrix}, \quad U = \begin{pmatrix} 6 & 2 & 1 & -1 \\ & \frac{10}{3} & \frac{2}{3} & \frac{1}{3} \\ & & \frac{37}{10} & -\frac{9}{10} \\ & & & \frac{191}{74} \end{pmatrix}.$$

例题求解 (代入)

第 2 步, 由式 (2) 得

$$y = \left(6, 3, \frac{23}{5}, -\frac{191}{74} \right)^T.$$

第 3 步, 由式 (3) 得

$$x = (1, -1, 1, -1)^T.$$

Cholesky 方法

设 $A \in C^{n \times n}$ 是 Hermite 正定矩阵, 则存在唯一的对角元素为正的下三角矩阵 L , 使 A 有 Cholesky 分解

$$A = LL^H.$$

利用 A 的 Cholesky 分解来求解线性方程组 $Ax = b$ 的方法称为 Cholesky 方法或平方根法.

这样求解线性方程组 $Ax = b$ 转化为求解下三角方程组 $Ly = b$ 和上三角方程组 $L^Hx = y$.

计算公式

记 $L = (l_{ij})$, 其中 $l_{ij} = 0 (j > i)$, 而

$$\begin{cases} l_{jj} = \left(a_{jj} - \sum_{k=1}^{j-1} |l_{jk}|^2 \right)^{\frac{1}{2}}, \\ l_{ij} = \left(a_{ij} - \sum_{k=1}^{j-1} l_{ik} \bar{l}_{jk} \right) / l_{jj} \quad (i = j+1, \dots, n) \\ \quad \quad \quad (j = 1, 2, \dots, n) \end{cases}$$

改进平方根法

Cholesky 分解 $A = LL^H$ 也可以修改为 $A = LDL^H$, 其中 L 为单位下三角矩阵, D 为对角线元素大于零的对角矩阵. 事实上令

$$\begin{aligned}
 A &= LDL^H \\
 &= \begin{pmatrix} 1 & & & 0 \\ l_{21} & 1 & & \\ \vdots & & \ddots & \\ l_{n1} & l_{n2} & \cdots & 1 \end{pmatrix} \begin{pmatrix} d_{11} & & & 0 \\ & d_{22} & & \\ & & \ddots & \\ 0 & & & d_{nn} \end{pmatrix} \begin{pmatrix} 1 & \bar{l}_{21} & \cdots & \bar{l}_{n1} \\ & 1 & \cdots & \bar{l}_{n2} \\ & & \ddots & \vdots \\ 0 & & & 1 \end{pmatrix} \\
 &= \begin{pmatrix} d_{11} & & & 0 \\ s_{21} & d_{22} & & \\ \vdots & & \ddots & \\ s_{n1} & s_{n2} & \cdots & d_{nn} \end{pmatrix} \begin{pmatrix} 1 & \bar{l}_{21} & \cdots & \bar{l}_{n1} \\ & 1 & \cdots & \bar{l}_{n2} \\ & & \ddots & \vdots \\ 0 & & & 1 \end{pmatrix}
 \end{aligned}$$

其中 $s_{ij} = l_{ij}d_{jj}$.

系数比较

比较元素得

$$\begin{cases} d_{11} = a_{11}; \\ s_{ij} = a_{ij} - \sum_{k=1}^{j-1} s_{ik} \bar{l}_{jk}; \\ l_{ij} = s_{ij} / d_{jj}, j = 1, 2, \dots, i-1; \\ d_{ii} = a_{ii} - \sum_{k=1}^{i-1} s_{ik} \bar{l}_{ik}. \end{cases} \quad (4)$$

求解步骤

解方程组 $Ax = b$ 转化为求解下三角方程组 $Ly = b$ 和上三角方程组 $L^H x = D^{-1}y$, 即

$$\begin{cases} y_i = b_i - \sum_{k=1}^{i-1} l_{ik} y_k; \\ x_i = y_i / d_{ii} - \sum_{k=i+1}^n \bar{l}_{ki} x_k, \quad i = 1, 2, \dots, n. \end{cases} \quad (5)$$

这一方法称为改进平方根法.

例题

用改进平方根法求解方程组 $Ax = b$ ，其中

$$A = \begin{pmatrix} 1 & 2 & 1 & -3 \\ 2 & 5 & 0 & -5 \\ 1 & 0 & 14 & 1 \\ -3 & -5 & 1 & 15 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 2 \\ 16 \\ 8 \end{pmatrix}.$$

例题求解 (逐步计算)

解: 按 (4) 计算分解式

$$i = 1: \quad d_{11} = 1$$

$$i = 2: \quad s_{21} = 2, \quad l_{21} = 2, \quad d_{22} = 1$$

$$i = 3: \quad s_{31} = 1, \quad l_{31} = 1, \\ s_{32} = -2, \quad l_{32} = -2, \quad d_{33} = 9$$

$$i = 4: \quad s_{41} = -3, \\ s_{42} = 1, \quad l_{42} = 1, \\ s_{43} = 6, \quad l_{43} = \frac{2}{3}, \quad d_{44} = 1$$

例题求解 (结果)

依照 (5) 解方程组得

$$y_1 = 1, y_2 = 0, y_3 = 15, y_4 = 1 ;$$

$$x_4 = 1, x_3 = 1, x_2 = 1, x_1 = 1.$$

三对角方程组的追赶法

定义: 设 $A \in C^{n \times n}$, 如果对 $|i - j| > m$ 时, 有 $a_{ij} = 0$, 我们就称 A 是带宽为 $2m + 1$ 的带状矩阵.

带宽为 3 的带状矩阵称为三对角矩阵, 形如 (6)

$$A = \begin{pmatrix} a_1 & c_1 & & & \\ u_2 & a_2 & c_2 & & \\ & \ddots & \ddots & \ddots & \\ & & u_{n-1} & a_{n-1} & \\ 0 & & & u_n & \end{pmatrix} \quad (6)$$

注: 在一些实际问题中, 例如解常微分方程边值问题, 解热传导方程以及船体数学放样中建立三次样条函数等, 都会要求解系数矩阵为对角占优的三对角线方程组。

三对角矩阵分解

设 A 是三对角矩阵 (6), 如果 A 的顺序主子式皆非零, 则 A 有如下三角分解

$$A = PQ = \begin{pmatrix} 1 & & & 0 \\ p_2 & 1 & & \\ & \ddots & \ddots & \\ 0 & & p_n & 1 \end{pmatrix} \begin{pmatrix} q_1 & r_1 & & 0 \\ & q_2 & \ddots & \\ & & \ddots & r_{n-1} \\ 0 & & & q_n \end{pmatrix}$$

其中

$$\begin{cases} r_i = c_i, \quad i = 1, 2, \dots, n-1; \\ q_i = a_i - p_i c_{i-1}, \quad i = 1, 2, \dots, n; \quad c_0 = 0; \\ p_i = u_i / q_{i-1}, \quad i = 2, 3, \dots, n; \\ p_1 = 0. \end{cases} \quad (7)$$

从 $Py = b$ 及 $Qx = y$ 得

$$\begin{cases} y_i = b_i - p_i y_{i-1}, & i = 1, 2, \dots, n; y_0 = 0; \\ x_i = (y_i - c_i x_{i+1}) / q_i, & i = n, n-1, \dots, 1; \\ x_{n+1} = 0. \end{cases} \quad (8)$$

按 (7) 及 (8) 求解 x 的方法称为追赶法,

第一个过程称为“追”过程: 从 y_1 开始, 一路“追”着算到 y_n ,

第二个过程称为“赶”过程: 从 x_n 开始, 倒着“赶”回来算到 x_1 。

例题

用追赶法解三对角方程组

$$\begin{pmatrix} 2 & -1 & & \\ -1 & 2 & -1 & \\ & -1 & 2 & -1 \\ & & -1 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 0 \\ 1 \end{pmatrix}.$$

例题求解

解: 设系数矩阵有分解

$$\begin{pmatrix} 2 & -1 & & \\ -1 & 2 & -1 & \\ & -1 & 2 & -1 \\ & & -1 & 2 \end{pmatrix} = \begin{pmatrix} 1 & & & \\ p_2 & 1 & & \\ & p_3 & 1 & \\ & & p_4 & 1 \end{pmatrix} \begin{pmatrix} q_1 & r_1 & & \\ & q_2 & r_2 & \\ & & q_3 & r_3 \\ & & & q_4 \end{pmatrix}.$$

例题求解 (计算参数)

由公式 (7) 得

$$r_1 = c_1 = -1, r_2 = c_2 = -1, r_3 = c_3 = -1,$$

$$q_1 = a_1 = 2, p_2 = \frac{u_2}{q_1} = -\frac{1}{2}, q_2 = a_2 - p_2 c_1 = \frac{3}{2},$$

$$p_3 = \frac{u_3}{q_2} = -\frac{2}{3}, q_3 = a_3 - p_3 c_2 = \frac{4}{3},$$

$$p_4 = \frac{u_4}{q_3} = -\frac{3}{4}, q_4 = a_4 - p_4 c_3 = \frac{5}{4}.$$

例题求解 (结果)

依照 (8) 得方程组的解

$$y_1 = 1, y_2 = \frac{1}{2}, y_3 = \frac{1}{3}, y_4 = \frac{5}{4};$$

$$x_4 = 1, x_3 = 1, x_2 = 1, x_1 = 1.$$

线性方程组的数值解法（迭代解法）

迭代法的一般概念

设 $A \in R_n^{n \times n}$, $b \in R^n$, 考虑线性方程组 $Ax = b$, 将其变为同解方程组 $x = Bx + f$, 形成迭代格式

$$x^{(k+1)} = Bx^{(k)} + f, \quad k = 0, 1, \dots \quad (1)$$

其中 B 称为迭代矩阵, $x^{(0)}$ 是任给的初始向量.

由于 $x^{(k+1)}$ 是 $x^{(k)}$ 的线性函数, (1) 称为线性迭代.

定义

如果迭代公式 (1) 产生的序列 $\{x^{(k)}\}$ 满足

$$\lim_{k \rightarrow \infty} x^{(k)} = x^*, x^{(0)} \in R^n$$

则称迭代法 (1) 是收敛的.

定理

下面三个命题是等价的:

- (i) 迭代法 $x^{(k+1)} = Bx^{(k)} + f$ 收敛.
- (ii) $\rho(B) < 1$.
- (iii) 至少存在一个矩阵范数 $\|\cdot\|$, 使 $\|B\| < 1$.

定理

设 x^* 是方程 $x = Bx + f$ 的唯一解, $\|B\| < 1$, 则由 (1) 产生的向量序列 $x^{(k)}$ 满足

$$\|x^{(k)} - x^*\| \leq \frac{\|B\|}{1 - \|B\|} \|x^{(k)} - x^{(k-1)}\|; \quad (2)$$

$$\|x^{(k)} - x^*\| \leq \frac{\|B\|^k}{1 - \|B\|} (\|f\| + 2\|x^{(0)}\|). \quad (3)$$

误差估计

式 (3) 可用来估计达到指定精度需要的迭代次数, 若要使 $\|x^{(k)} - x^*\| \leq \varepsilon$, 只要

$$\frac{\|B\|^k}{1 - \|B\|} (\|f\| + 2\|x^{(0)}\|) \leq \varepsilon,$$

即

$$k \geq \ln \left(\frac{\varepsilon (1 - \|B\|)}{\|f\| + 2\|x^{(0)}\|} \right) / \ln \|B\|.$$

收敛速度

在线性迭代法中, 我们用 $R(B) = -\ln \rho(B)$ 表示迭代法的收敛速度. 现在来确定迭代次数 k , 使

$$[\rho(B)]^k < 10^{-\varepsilon}.$$

取对数得

$$k \geq \frac{\varepsilon \ln 10}{-\ln \rho(B)}$$

由此看出, 当 $R(B) = -\ln \rho(B)$ 越大, 上式成立所需迭代次数越少, 表明迭代次数与收敛速度成反比.

迭代法的构造

如将 A 分裂为

$$A = M - N \quad (4)$$

其中 M 非奇异.

则由 $Ax = b$ 可得

$$x = M^{-1}Nx + M^{-1}b. \quad (5)$$

令

$$B = M^{-1}N = I - M^{-1}A,$$

$$f = M^{-1}b$$

就可以得到 $x = Bx + f$ 的形式.

Jacobi 迭代法

考虑非奇异线性方程组 $Ax = b$, $a_{ii} \neq 0$, 把 A 分裂为 $A = D + L + U$, 其中

$$D = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$$

$$L = \begin{pmatrix} 0 & & & & \\ a_{21} & 0 & & & \\ a_{31} & a_{32} & 0 & & \\ \vdots & \vdots & \ddots & \ddots & \\ a_{n1} & a_{n2} & \cdots & a_{n,n-1} & 0 \end{pmatrix}, U = \begin{pmatrix} 0 & a_{12} & a_{13} & \cdots & a_{1n} \\ & 0 & a_{23} & \cdots & a_{2n} \\ & & \ddots & \ddots & \vdots \\ & & & 0 & a_{n-1,n} \\ & & & & 0 \end{pmatrix}$$

Jacobi 迭代法 (续)

对应于 (4) 形式的一般分裂式, 令 $M = D, N = -L - U$, 则 (5) 等价于

$$x = -D^{-1}(L + U)x + D^{-1}b.$$

由此构造迭代法

$$x^{(k+1)} = B_J x^{(k)} + f, \quad k = 0, 1, \dots, \quad (6)$$

其中向量 f 和迭代矩阵 B_J 为

$$f = D^{-1}b \quad (7)$$

$$B_J = -D^{-1}(L + U) = I - D^{-1}A.$$

(6) 称为 Jacobi 迭代法 (简称 J 法).

Jacobi 迭代格式

若给定初始向量 $x^{(0)} = (x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)})^T$, 则 Jacobi 迭代格式为

$$x_i^{(k+1)} = \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij} x_j^{(k)} \right) \frac{1}{a_{ii}},$$

$$i = 1, 2, \dots, n; k = 0, 1, 2, \dots$$

Gauss-Seidel 迭代法

如果令 $M = D + L$, $N = -U$, 对应于 (4) 的分裂式有

$$f = (D + L)^{-1}b \quad (8)$$

$$B_G = -(D + L)^{-1}U = I - (D + L)^{-1}A,$$

便得到 Gauss-Seidel 迭代法 (简称 G-S 法)

$$x^{(k+1)} = B_G x^{(k)} + f, \quad k = 0, 1, \dots \quad (9)$$

Gauss-Seidel 迭代格式

若给定初始向量 $x^{(0)} = (x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)})^T$, 则 Gauss-Seidel 迭代格式为

$$x_i^{(k+1)} = \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right) \frac{1}{a_{ii}},$$

$$i = 1, 2, \dots, n; k = 0, 1, 2, \dots$$

J 法与 G-S 法的收敛性

J 法和 G-S 法并无包含关系.

如设方程组的系数矩阵分别为

$$A_1 = \begin{pmatrix} 1 & 2 & -2 \\ 1 & 1 & 1 \\ 2 & 2 & 1 \end{pmatrix}, A_2 = \begin{pmatrix} 2 & -1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & -2 \end{pmatrix}$$

可验证: A_1 对 J 法是收敛的, 但 G-S 法不收敛; 而 A_2 对 J 法不收敛, 但 G-S 法收敛.

定义

若 $A = (a_{ij}) \in R^{n \times n}$, 满足

$$|a_{ii}| > \sum_{j=1, j \neq i}^n |a_{ij}|, \quad i = 1, 2, \dots, n,$$

称 A 为严格对角占优矩阵.

若 A 满足

$$|a_{ii}| \geq \sum_{j=1, j \neq i}^n |a_{ij}|, \quad i = 1, 2, \dots, n,$$

且其中最少有一个严格不等式成立, 称 A 为弱对角占优矩阵.

定义

设 $A = (a_{ij}) \in R^{n \times n}$, 若不能找到置换矩阵 P , 使得

$$P^T A P = \begin{pmatrix} \tilde{A}_{11} & \tilde{A}_{12} \\ 0 & \tilde{A}_{22} \end{pmatrix} \quad (10)$$

其中 $\tilde{A}_{11}$ 与 $\tilde{A}_{22}$ 均为方阵, 则称 A 为不可约矩阵.

定理

- 若 $A = (a_{ij})$ 严格对角占优, 则 $a_{ii} \neq 0, i = 1, 2, \dots, n$, 且 A 非奇异.
- 若 $A = (a_{ij})$ 不可约且弱对角占优, 则 $a_{ii} \neq 0, i = 1, 2, \dots, n$, 且 A 非奇异.

定理

若系数矩阵 A 严格对角占优或不可约弱对角占优矩阵, 则 Jacobi 迭代法和 G-S 迭代法收敛.

证明

若矩阵 A 严格对角占优, 则 $|a_{ii}| > 0$, 因此 D 可逆. 现假设 Jacobi 迭代矩阵 B_J 的某个特征值 λ 满足 $|\lambda| \geq 1$, 那么矩阵 $\lambda D + L + U$ 也是严格对角占优的, 因此 $\lambda D + L + U$ 非奇异. 再由

$$\lambda I - B_J = \lambda I + D^{-1}(L + U) = D^{-1}(\lambda D + L + U)$$

可知 $\lambda I - B_J$ 非奇异, 所以 $\det(\lambda I - B_J) \neq 0$, 这与 λ 是 B_J 的特征值矛盾. 故 B_J 的特征值的模均小于 1, 即 Jacobi 迭代收敛.

超松弛迭代法

在 G-S 迭代格式中

$$x^{(k+1)} = -D^{-1}Lx^{(k+1)} - D^{-1}Ux^{(k)} + D^{-1}b$$

令 $\Delta x = x^{(k+1)} - x^{(k)}$ ，则有 $x^{(k+1)} = x^{(k)} + \Delta x$ 。

若修正项 Δx 乘上一个参数 α ，便得到超松弛迭代法，简记为 SOR 法，其计算式

$$x^{(k+1)} = x^{(k)} - \alpha D^{-1} \left[Lx^{(k+1)} + (D + U)x^{(k)} - b \right] .$$

SOR 法的线性迭代形式

超松弛法也是线性迭代

$$\begin{cases} x^{(k+1)} = B_{\alpha} x^{(k)} + f_{\alpha}; \\ B_{\alpha} = (D + \alpha L)^{-1} [(1 - \alpha) D - \alpha U]; \\ f_{\alpha} = \alpha (D + \alpha L)^{-1} b. \end{cases}$$

用分量形式即是

$$x_i^{(k+1)} = x_i^{(k)} + \frac{\alpha}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i}^n a_{ij} x_j^{(k)} \right)$$
$$i = 1, 2, \dots, n.$$

SOR 法的收敛性

- 定理: 在矩阵 A 是实对称正定矩阵的条件下, SOR 法收敛的充要条件是 $0 < \alpha < 2$.
- 定理: 若矩阵 A 严格对角占优或不可约弱对角占优, 则当 $0 < \alpha \leq 1$ 时, SOR 法收敛.

例题: SOR 法

例用 SOR 法求解方程组

$$\begin{cases} 4x_1 - x_2 & = 1 \\ -x_1 + 4x_2 - x_3 & = 4 \\ -x_2 + 4x_3 & = -3 \end{cases}$$

分别取 $\alpha = 1.03, \alpha = 1, \alpha = 1.1$, 要求当

$\|x^* - x^{(k)}\|_{\infty} \leq 5 \times 10^{-6}$ 时迭代终止, 并对每个 α 确定迭代次数, 其中精确解 $x^* = (\frac{1}{2}, 1, -\frac{1}{2})^T$.

SOR 法求解过程

解: SOR 迭代格式为

$$\begin{cases} x_1^{(k+1)} = (1 - \alpha) x_1^{(k)} + \frac{\alpha}{4} \left(1 + x_2^{(k)} \right) \\ x_2^{(k+1)} = (1 - \alpha) x_2^{(k)} + \frac{\alpha}{4} \left(4 + x_1^{(k+1)} + x_3^{(k)} \right) \\ x_3^{(k+1)} = (1 - \alpha) x_3^{(k)} + \frac{\alpha}{4} \left(-3 + x_2^{(k+1)} \right). \end{cases}$$

取初始向量 $x^{(0)} = (0, 0, 0)^T$, 当 $\alpha = 1.03$ 时, 迭代 5 次达到要求,

$$x^{(5)} = (0.50000043, 1.0000001, -0.499999)^T.$$

SOR 法求解过程 (续)

当 $\alpha = 1$ 时, 迭代 6 次达到要求,

$$x^{(6)} = (0.50000038, 1.0000002, -0.4999995)^T.$$

当 $\alpha = 1.1$ 时, 迭代 6 次达到要求,

$$x^{(6)} = (0.50000035, 0.9999989, -0.5000003)^T.$$

线性方程组的解（极小化方法）

与方程组等价的变分问题

考虑方程组

$$Ax = b$$

其中 A 为 n 阶对称正定矩阵, $b \in R^n$ 为给定向量.

定义二次函数

$$\begin{aligned}\varphi(x) &= \frac{1}{2} (Ax, x) - (b, x) \\ &= \frac{1}{2} x^T A x - b^T x.\end{aligned}$$

函数 φ 的性质

1. 对一切 $x \in R^n$, $\text{grad } \varphi(x) = Ax - b$.
2. 对一切 $x, y \in R^n, \alpha \in R$,

$$\begin{aligned}\varphi(x + \alpha y) &= \frac{1}{2} (A(x + \alpha y), x + \alpha y) - (b, x + \alpha y) \\ &= \varphi(x) + \alpha (Ax - b, y) + \frac{\alpha^2}{2} (Ay, y).\end{aligned}$$

3. 设 x^* 为 $Ax = b$ 的解, 则对一切 $x \in R^n$, 有

$$\varphi(x) - \varphi(x^*) = \frac{1}{2} (A(x - x^*), x - x^*). \quad (11)$$

定理

设 A 对称正定, 则 x^* 为方程组 $Ax = b$ 的解的充要条件是 x^* 满足

$$\varphi(x^*) = \min_{x \in R^n} \varphi(x).$$

证明 (必要性)

设 x^* 为 $Ax = b$ 的解, 由 (11) 及 A 的正定性, 有 $\varphi(x) - \varphi(x^*) \geq 0$, 即 x^* 使 $\varphi(x)$ 最小.

证明 (充分性)

设 $\varphi(x^*) = \min_{x \in \mathbb{R}^n} \varphi(x)$, 则对任意的 $y \in \mathbb{R}^n$, 由

$$f(\alpha) = \varphi(x^* + \alpha y) = \varphi(x^*) + \alpha(A^* - b, y) + \frac{\alpha^2}{2}(Ay, y)$$

可知

$$f'(0) = \left. \frac{d\varphi(x^* + \alpha y)}{d\alpha} \right|_{\alpha=0} = (Ax^* - b, y) = 0$$

由 y 的任意性可知必有 $Ax^* = b$

最速下降法定义

设 x_0 为初始点, 规定一方向 p_0 , 求函数 $f(x)$ 在直线

$$x = x_0 + tp_0$$

上的极小点 x_1 ;

从 x_1 出发规定一方向 p_1 , 求函数 $f(x)$ 在直线

$$x = x_1 + tp_1$$

上的极小点 x_2 ;

搜索方向

如此继续下去, 一般地, 从点 x_k 出发规定一方向 p_k , 求函数 $f(x)$ 在直线

$$x = x_k + tp_k$$

上的极小点 x_{k+1} , 称 p_k 为搜索方向.

确定步长

记 $f(t) = \varphi(x_k + tp_k)$, 欲确定 α_k 使得 f 在 $t = \alpha_k$ 时为极小.
由性质 2 知,

$$f(t) = \varphi(x_k) + t(Ax_k - b, p_k) + \frac{t^2}{2}(Ap_k, p_k)$$

由 $f'(t) = 0$, 得

$$t = \alpha_k = -\frac{(Ax_k - b)^T p_k}{p_k^T A p_k}$$

迭代公式

由于 $f''(t) = p_k^T A p_k > 0$ ($p_k \neq 0$)，因此 $t = \alpha_k$ 时， $f(t)$ 为极小。
记

$$r_k = Ax_k - b = \text{grad } \varphi(x_k),$$

那么

$$\alpha_k = -\frac{r_k^T p_k}{p_k^T A p_k}.$$

迭代公式为

$$x_{k+1} = x_k + \alpha_k p_k, \quad k = 0, 1, 2, \dots$$

最速下降法

(i) 如果选取

$$p_k = -r_k = -\text{grad } \varphi(x_k)$$

那么上述迭代法称为最速下降法.

此时

$$\begin{cases} x_{k+1} = x_k - \alpha_k r_k \\ \alpha_k = \frac{(r_k, r_k)}{(Ar_k, r_k)}. \end{cases}$$

最速下降法收敛性

因为

$$\begin{aligned}\varphi(x_{k+1}) - \varphi(x_k) &= \varphi(x_k + \alpha_k p_k) - \varphi(x_k) \\ &= -\alpha_k (r_k, r_k) + \frac{1}{2} \alpha_k^2 (A r_k, r_k) \\ &= -\frac{1}{2} \frac{(r_k, r_k)^2}{(A r_k, r_k)} < 0\end{aligned}$$


所以 $\varphi(x_{k+1}) < \varphi(x_k)$.

可以证明向量序列 $\{x^k\}$ 收敛于方程组 $Ax = b$ 的解, 并且相邻两次的搜索方向是正交的, 即

$$(r_{k+1}, r_k) = 0.$$

最速下降法图示

收敛方向固定，在条件数很大的时候收敛可能很慢。



Takeaways (线性方程组的解) :

1. 直接法: Gauss 消元法 (列主元法)、三角分解法、追赶法;
2. 迭代法: Jacobi 迭代法、Gauss-Seidel 迭代法、SOR 迭代法;
3. 优化法: 最速下降法

END
of
Chapter 5